CNN

Computer Vision & Image

Contents

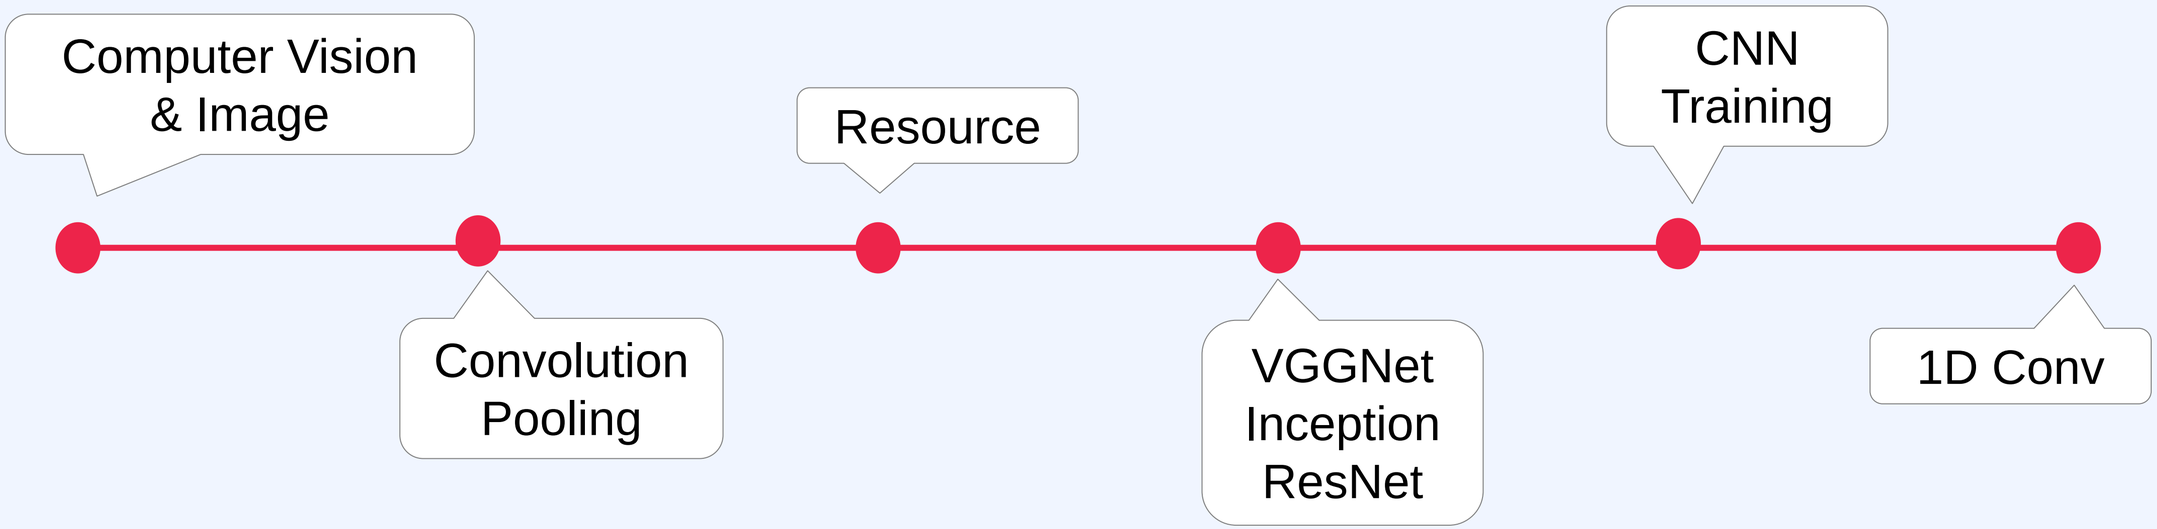

Computer Vision Task

- Image Classification(Single object)
- Localization(Single object)
- Object Detection(Multiple object)

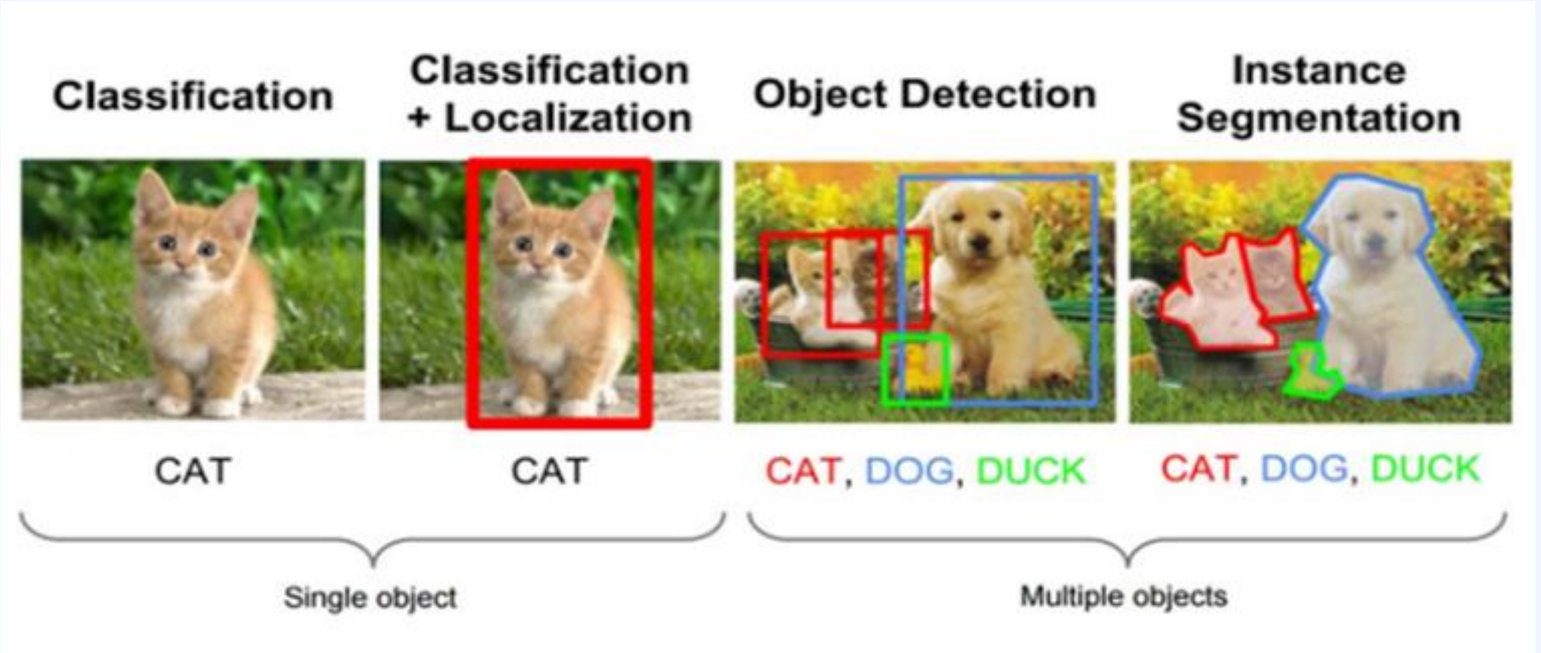

https://towardsdatascience.com/everything-you-ever-wanted-to-know-about-computer-vision-heres-a-look-why-it-s-so-awesome-e8a58dfb641e

Computer Vision Task

➢ Object Detection

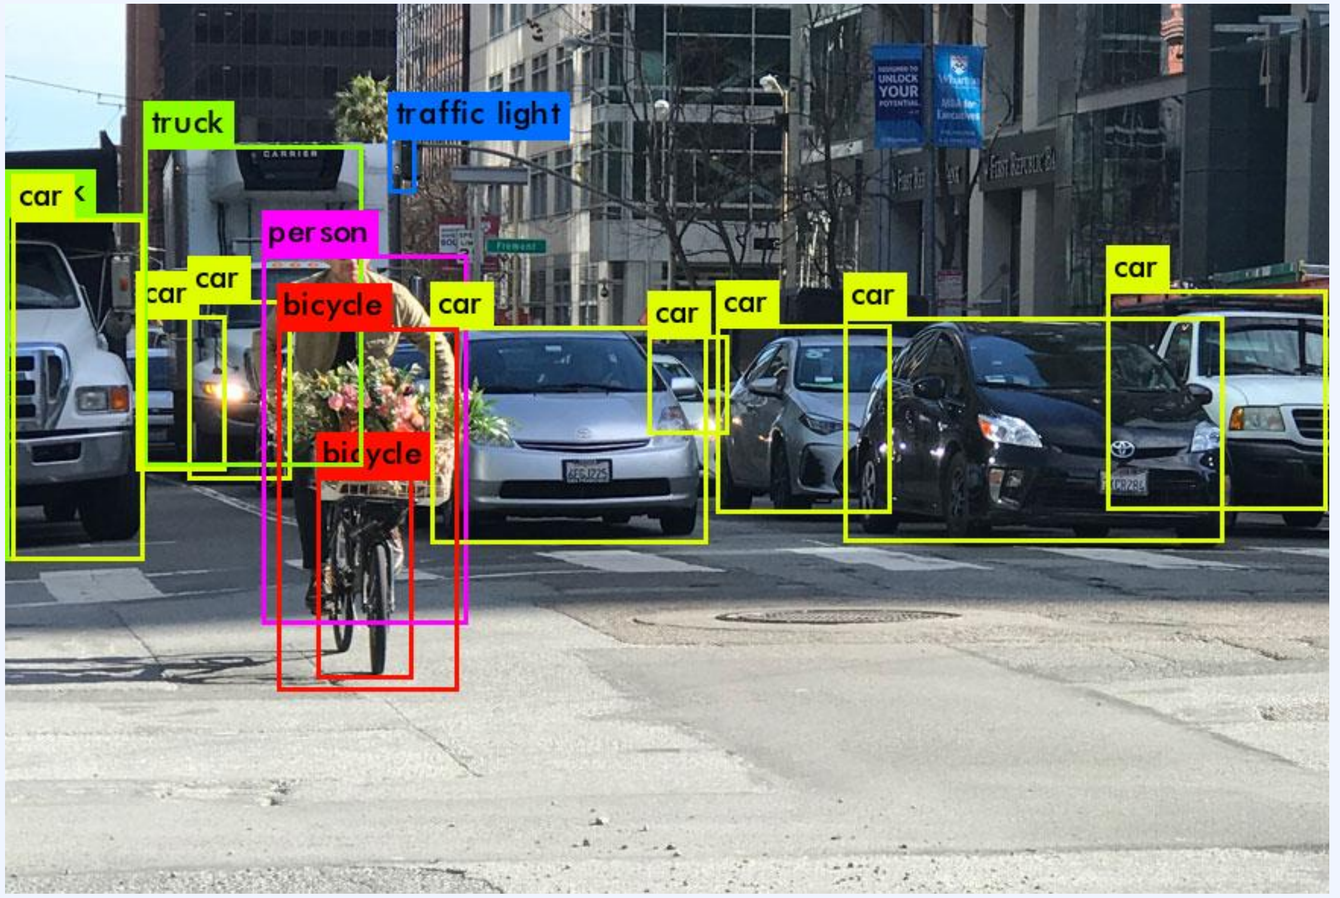

https://dagshub.com/blog/yolov6/

Computer Vision Task

➢ Automated colorization

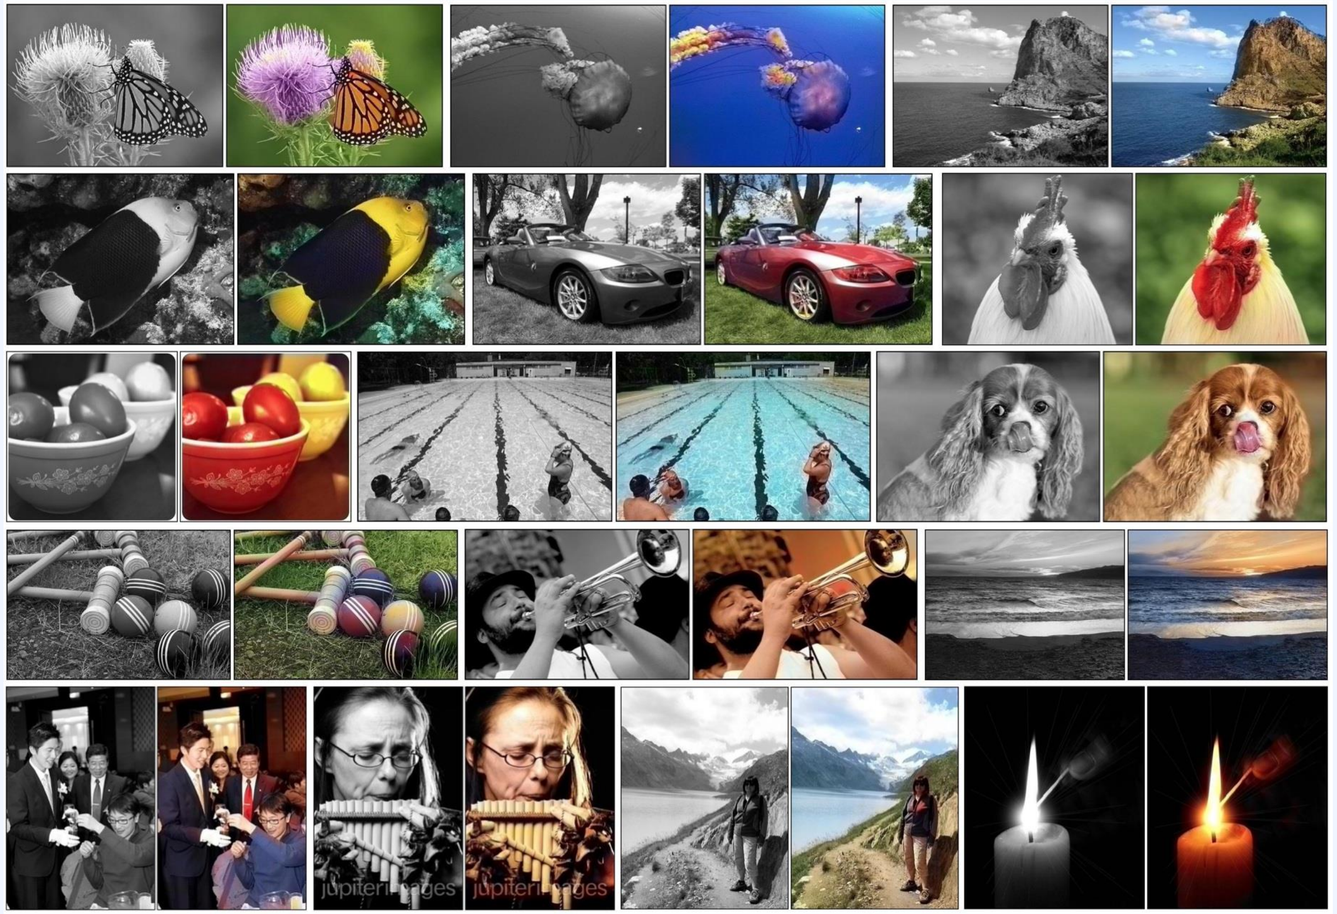

https://richzhang.github.io/colorization/

Computer Vision Task

➢ Automatic Image captioning

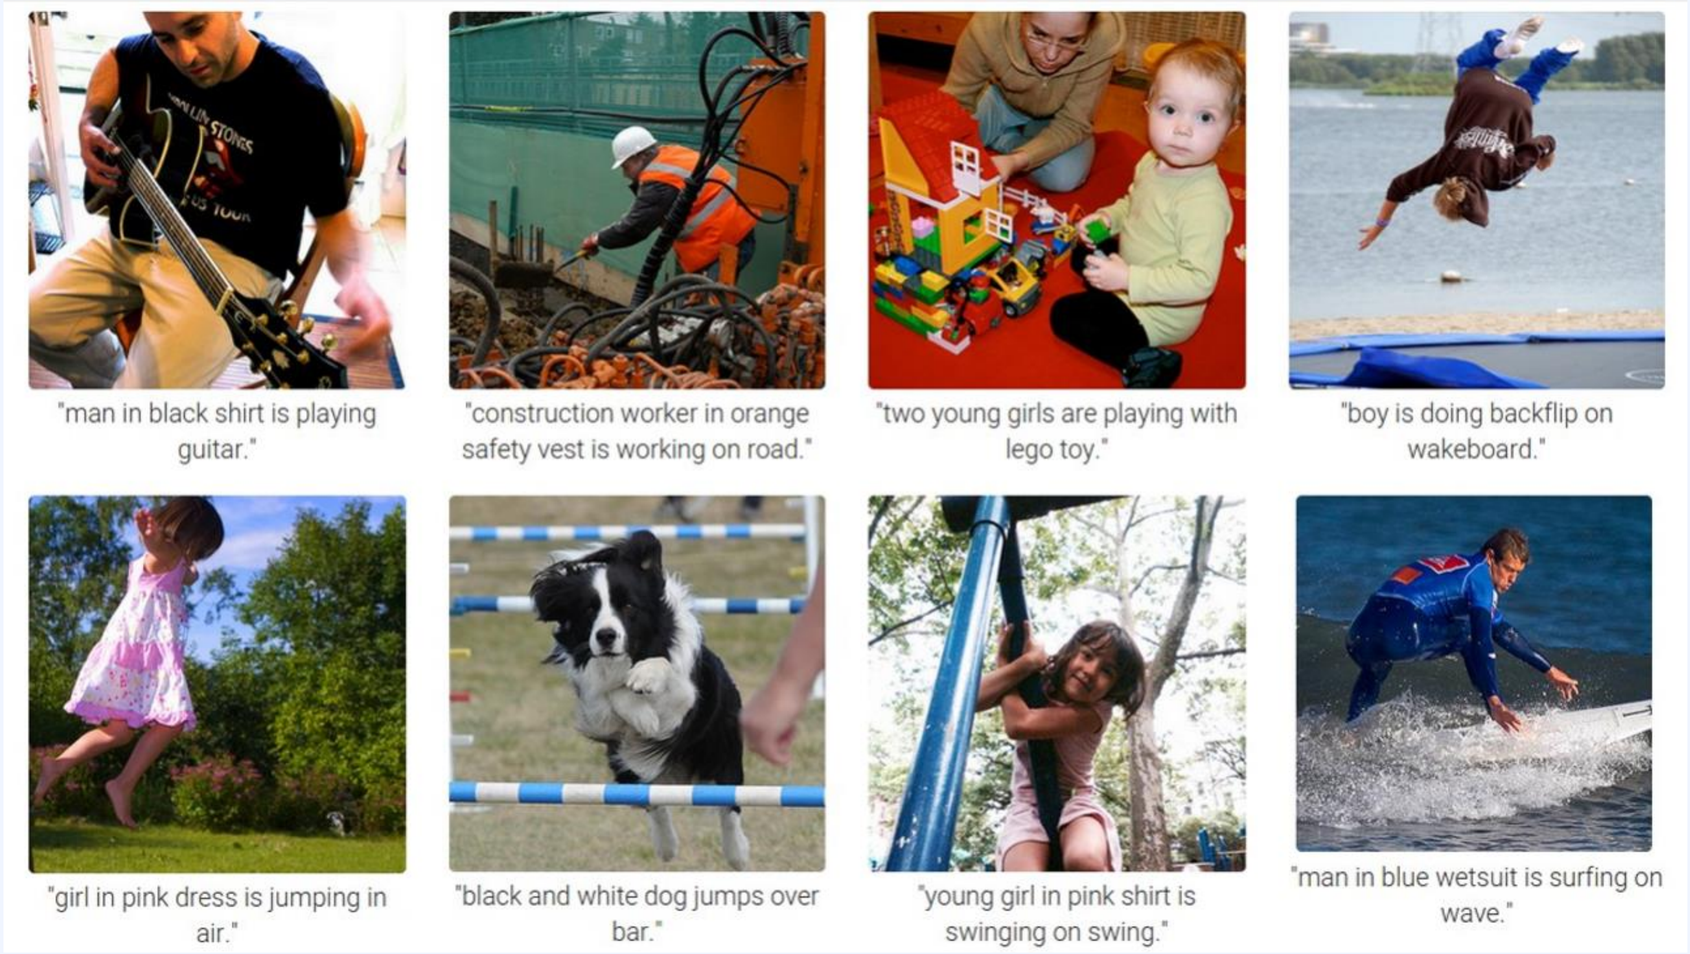

https://cs.stanford.edu/people/karpathy/sfmltalk.pdf

Computer Vision Task

➢ Translation

https://www.wsj.com/articles/BL-268B-1420

https://mashable.com/article/word-lens-japanese

Image?

➢ 이미지도 숫자다

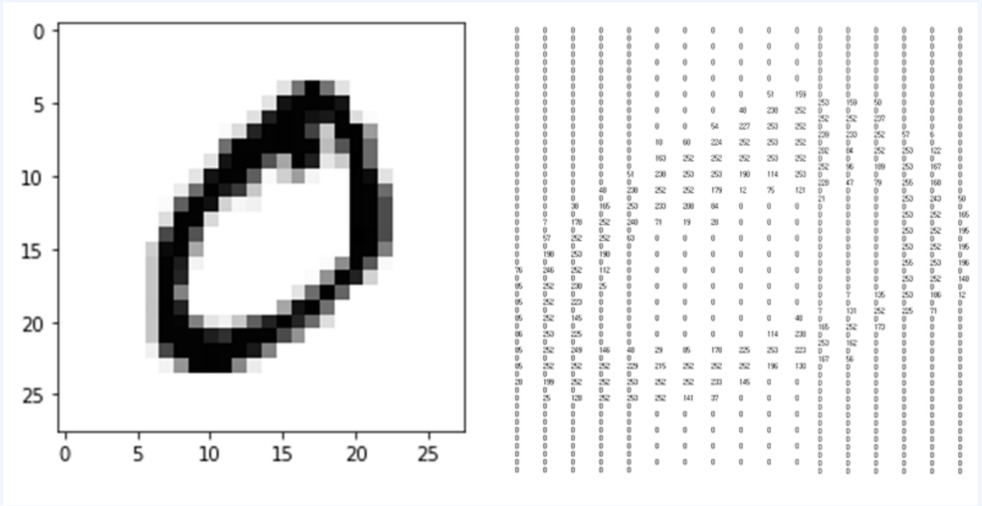

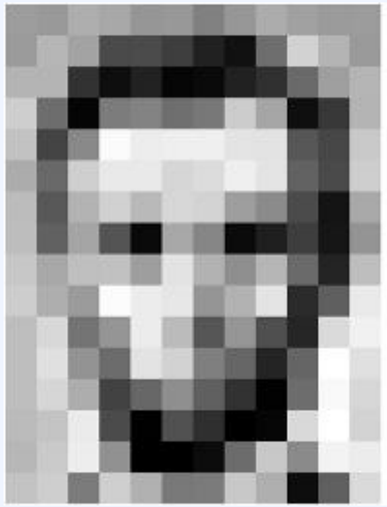

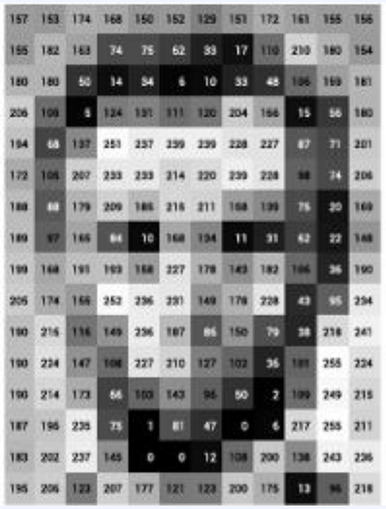

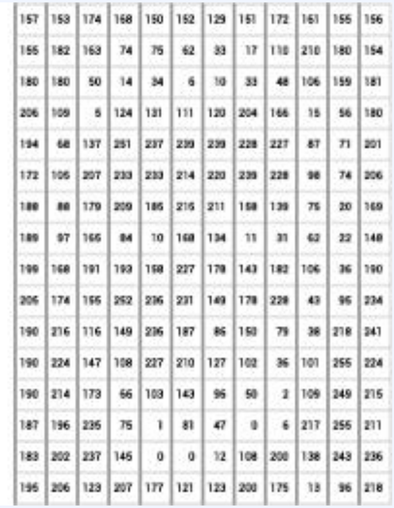

https://towardsdatascience.com/everything-you-ever-wanted-to-know-about-computer-vision-heres-a-look-why-it-s-so-awesome-e8a58dfb641e

Review

➢ Basic Neural Network

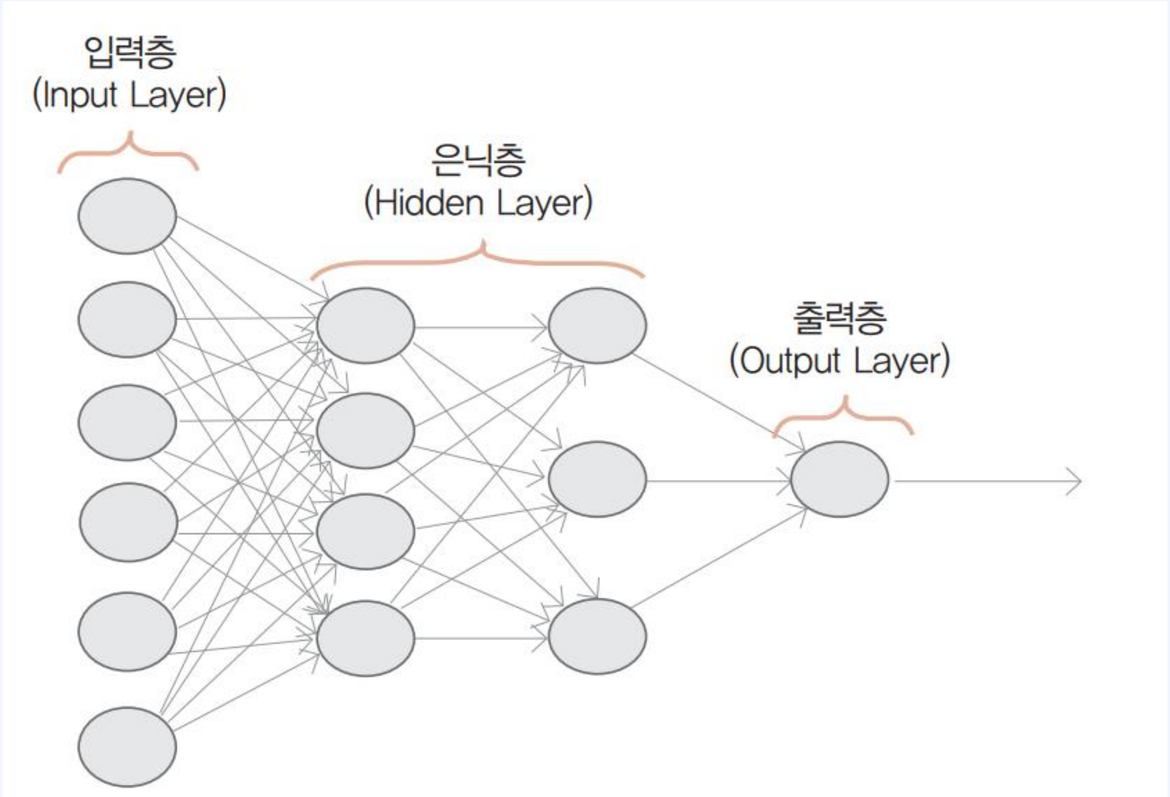

출처: 파이썬으로 시작하는 머신러닝+딥러닝(아이리포)

Review

- Basic Neural Network
  - 입력: 784(28*28)
    - 2차원 데이터를 1차원으로 변형하여 사용: 28 * 28 = 784 차원의 입력벡터
  - 은닉층: ??
  - 출력층: 10 (0~9까지의 숫자)

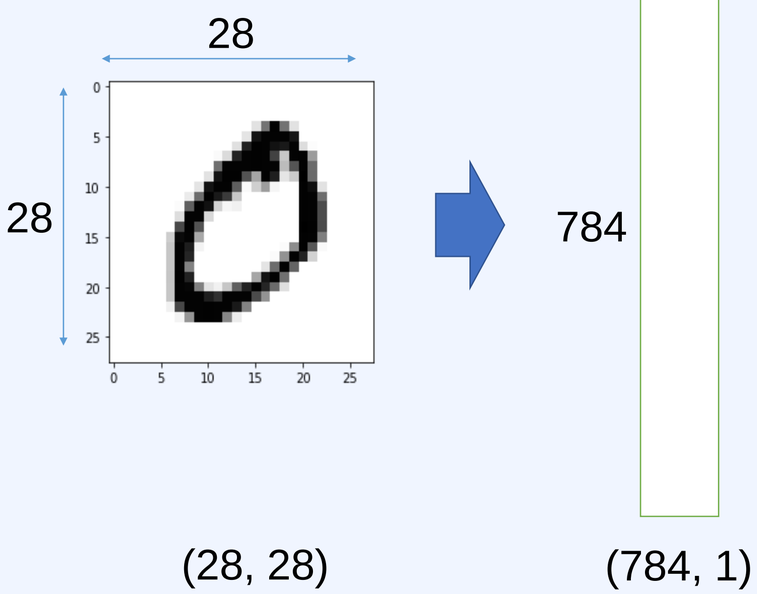

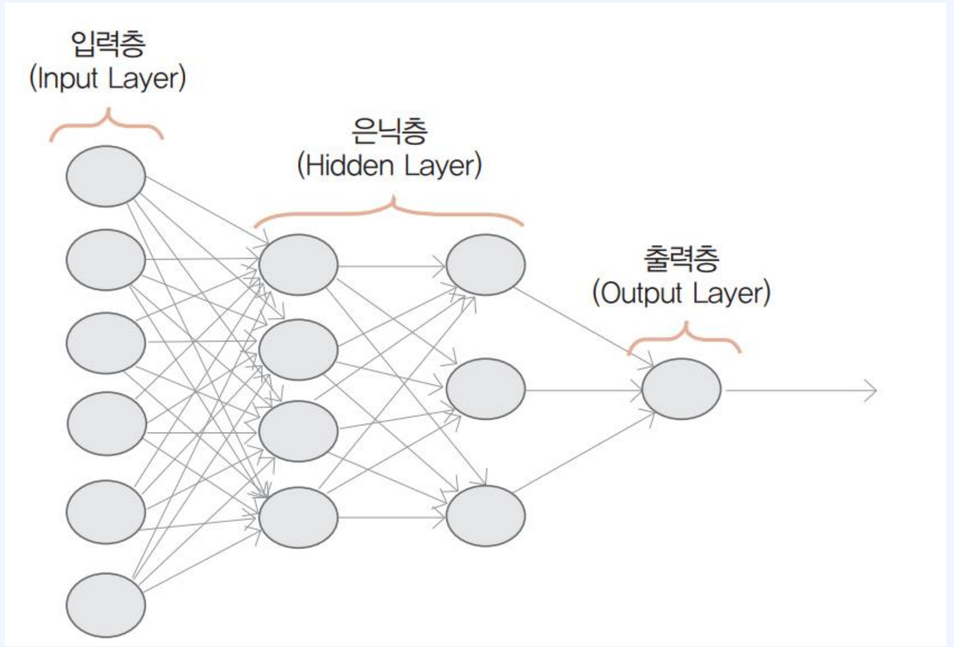

출처: 파이썬으로 시작하는 머신러닝+딥러닝(아이리포)

Why?

➢ 2D를 1D로 변환하면 이미지 고유의 특성을 잃어버린다….

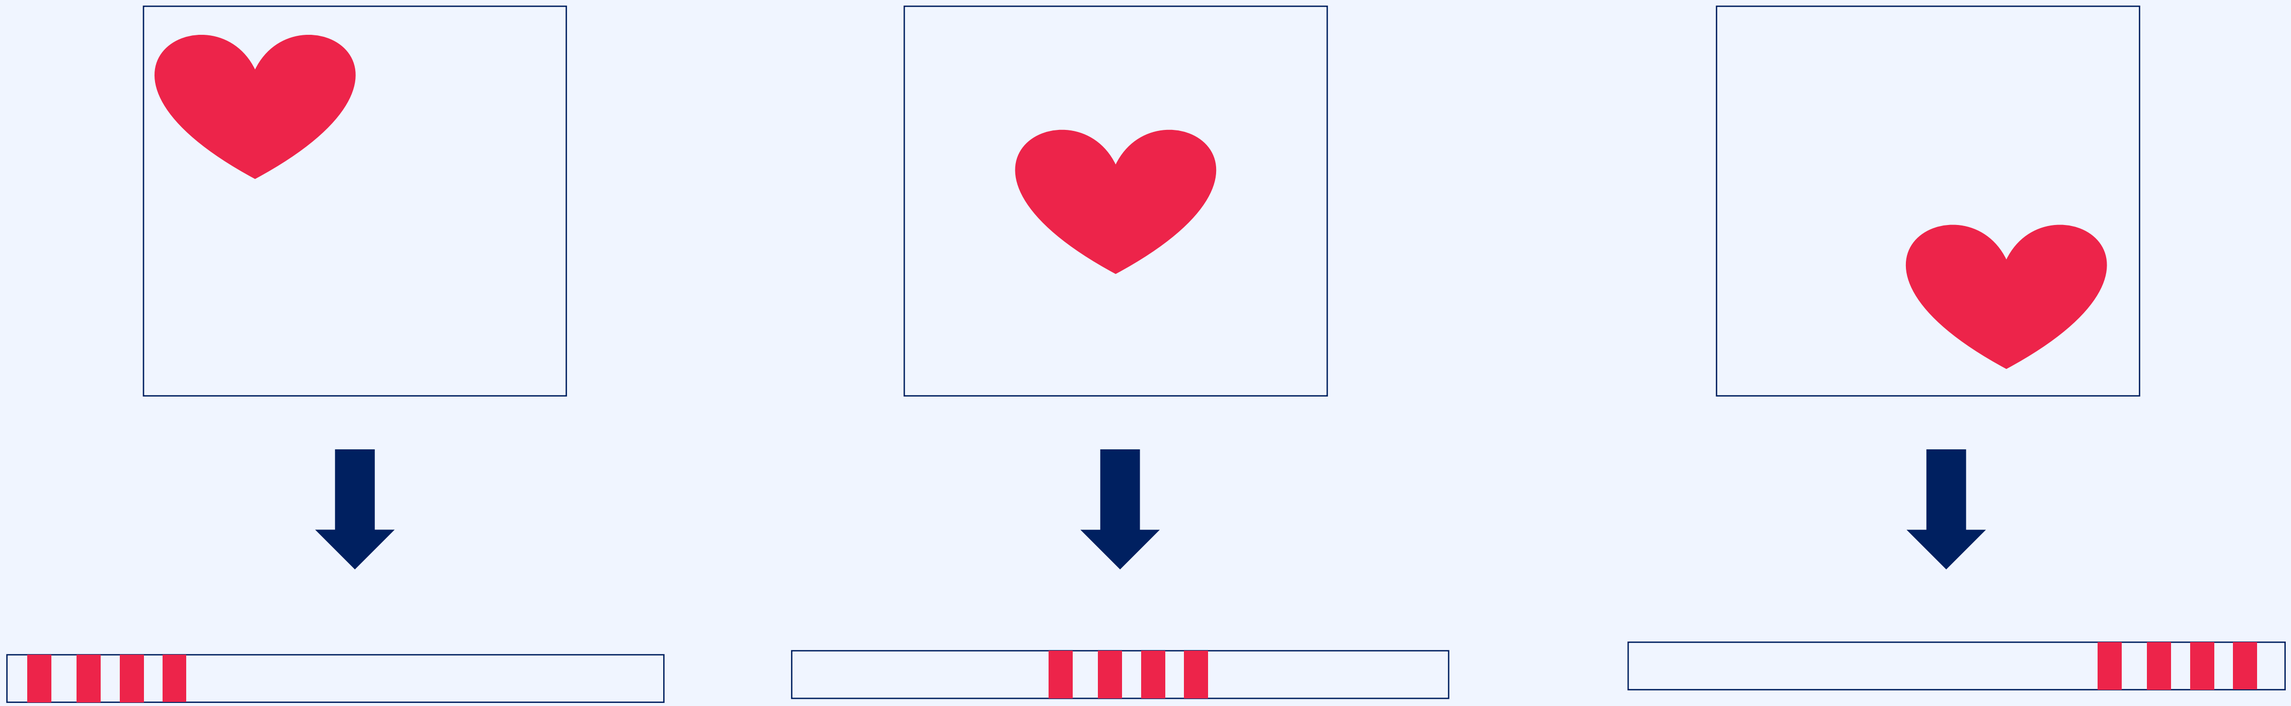

What?

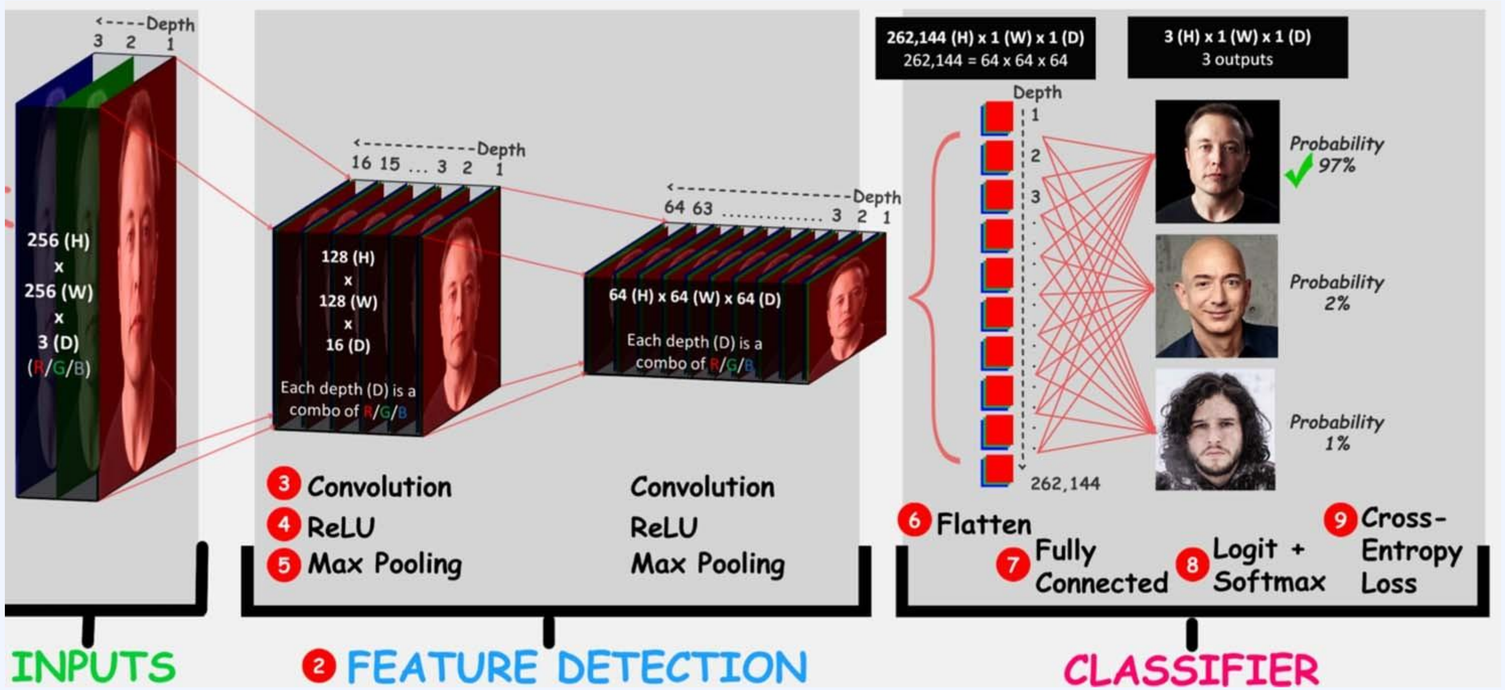

CNN

Convolution

Convolution

➢ Image classifier의 구성

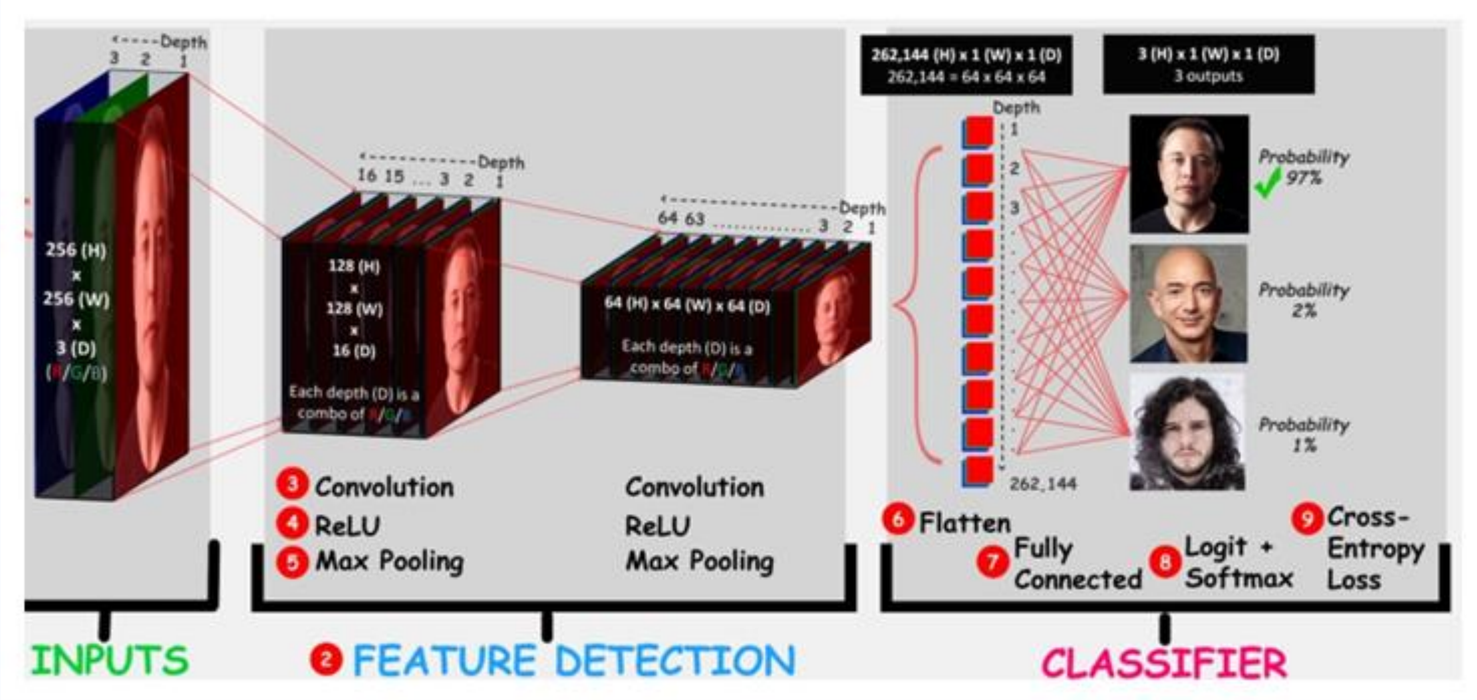

Convolutional Neural Network

➢ CNN이란?

- Convolution Layer로 구성된 이미지 처리에 좋은 성능을 가지는 인공 신경망
- 이미지 처리에만 사용되는 것은 아니지만, 이미지처럼 고차원 데이터에서 탁월한 성능을 보이기때문에 이미지 데이터를 활용한 태스크에 많이 활용됨
- 구성
  - Convolutional layer → pooling layer(subsampling) → Convolutional layer → pooling layer… → fully connected layer로 구성
  - 각 layer를 단순히 교차해서 조합하는 것은 아니고, 목적에 따라 조합하는 방법은 무궁무진함
  - Pooling layer가 항상 존재하는 것은 아님

Convolution

➢ Convolution 연산
- 데이터의 특징을 추출하기 위해 단계별로 다양한 필터(커널) 적용
- 필터 적용시 마다 이미지 왼쪽 위에서 오른쪽 아래까지 밀면서 곱하고 더하는 연산을 수행
- 효과
  - 이미지의 특징점을 효과적으로 찾는데 활용
  - 적은 수의 가중치로 이미지 처리를 효율적으로 할 수 있음

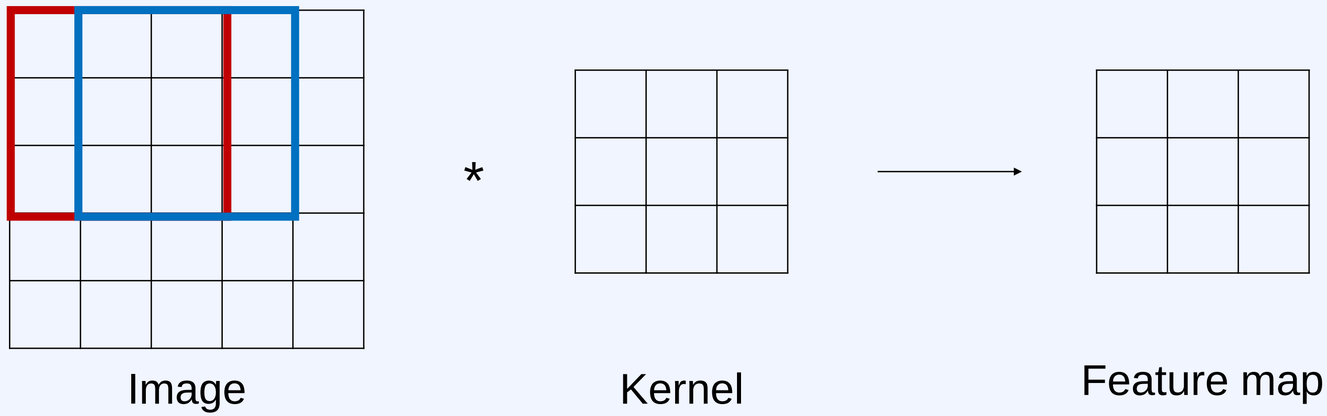

Convolution

➢ Convolution 연산

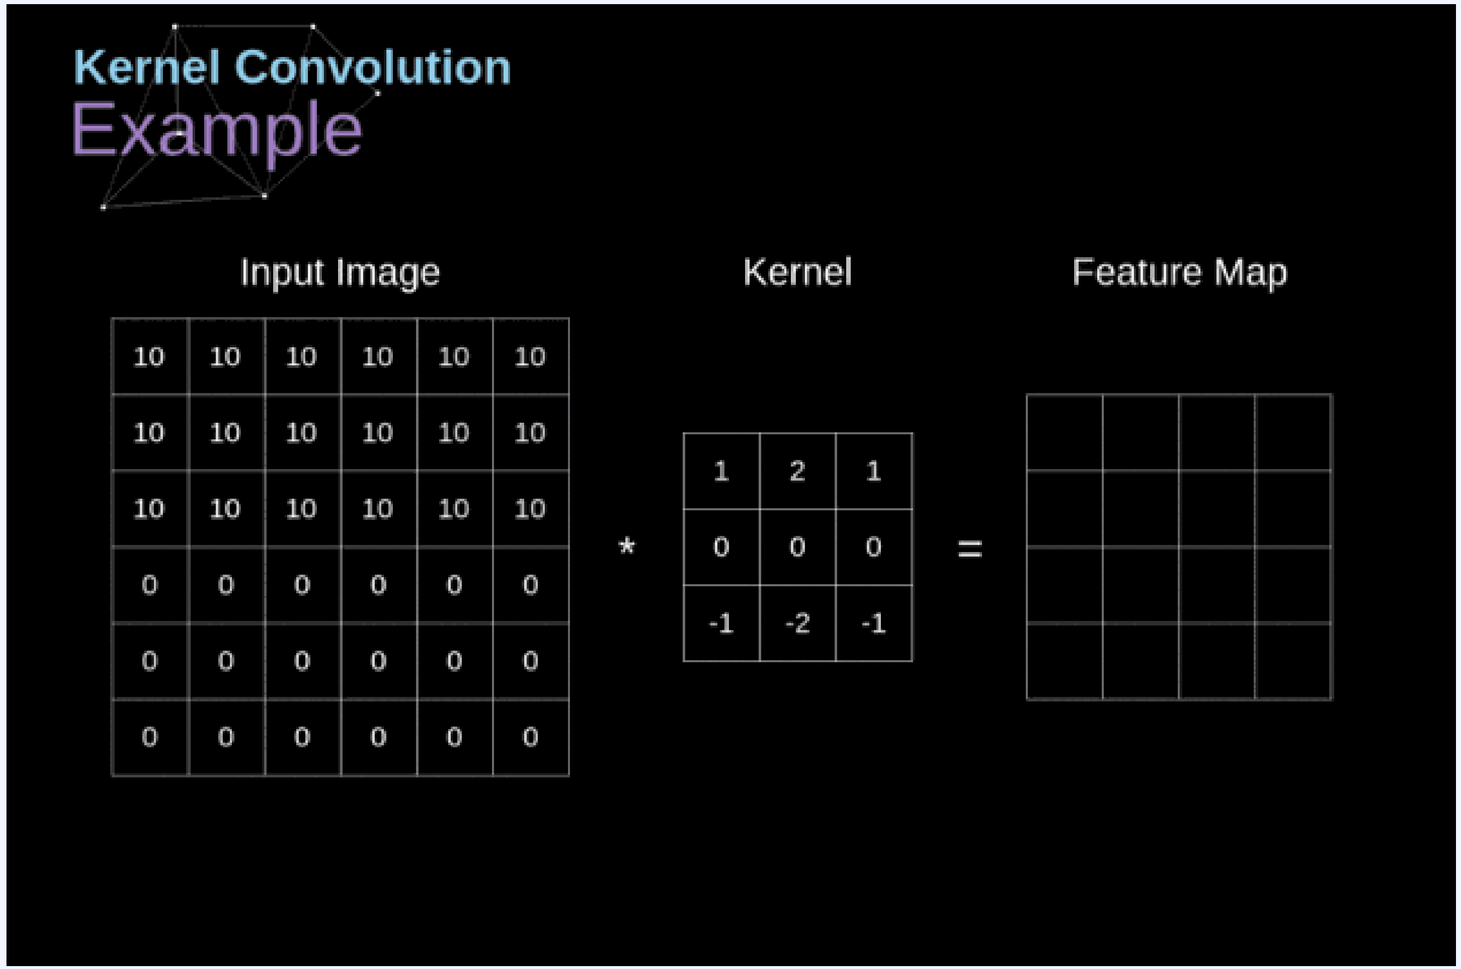

https://towardsdatascience.com/gentle-dive-into-math-behind-convolutional-neural-networks-79a07dd44cf9

Convolution

➢ Kernel? Feature Map?

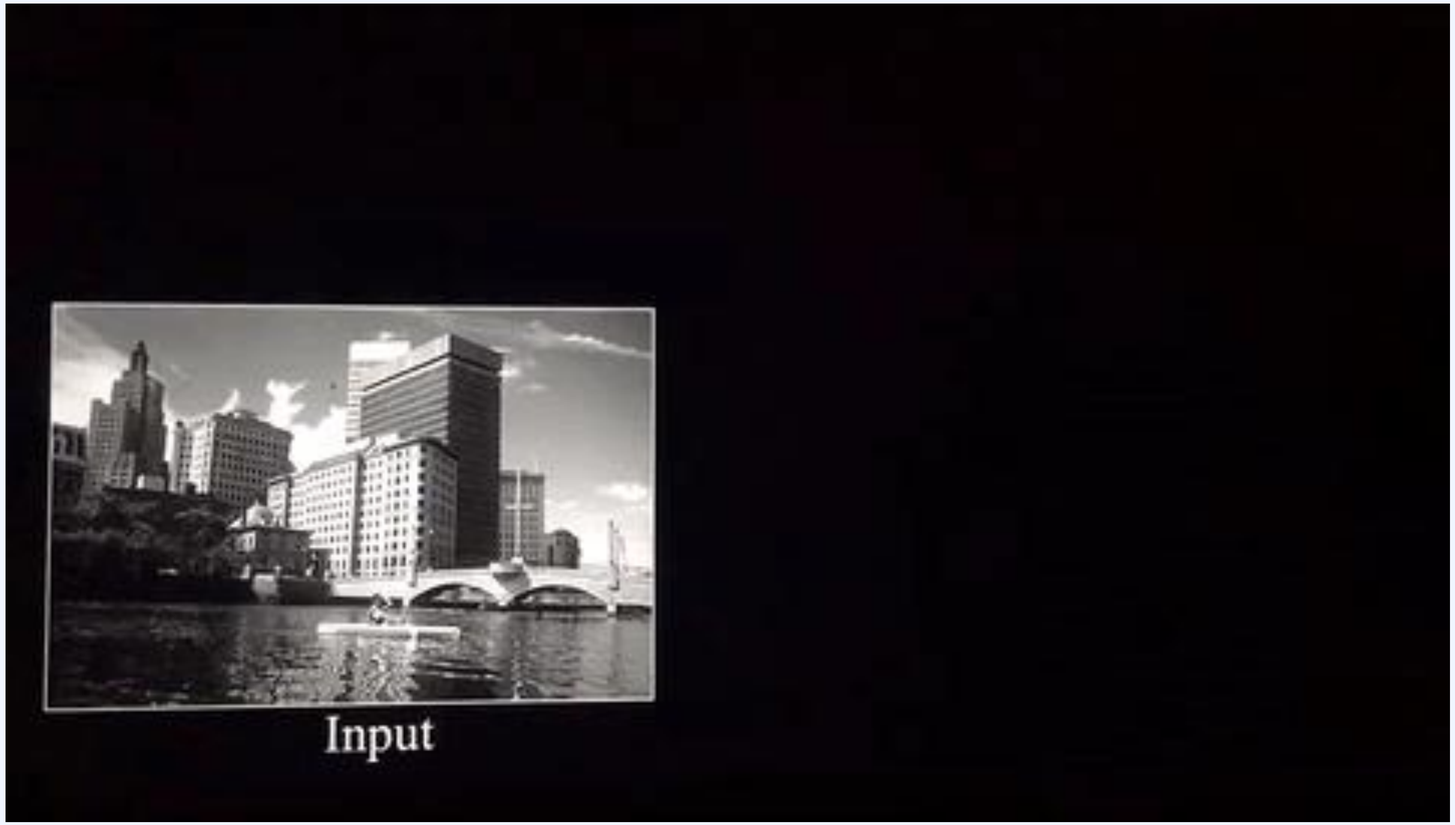

Convolution

➢ Feature map
- Convolution 연산을 수행할수록 점점 복잡한 형태의 고차원 특징을 추출할 수 있음

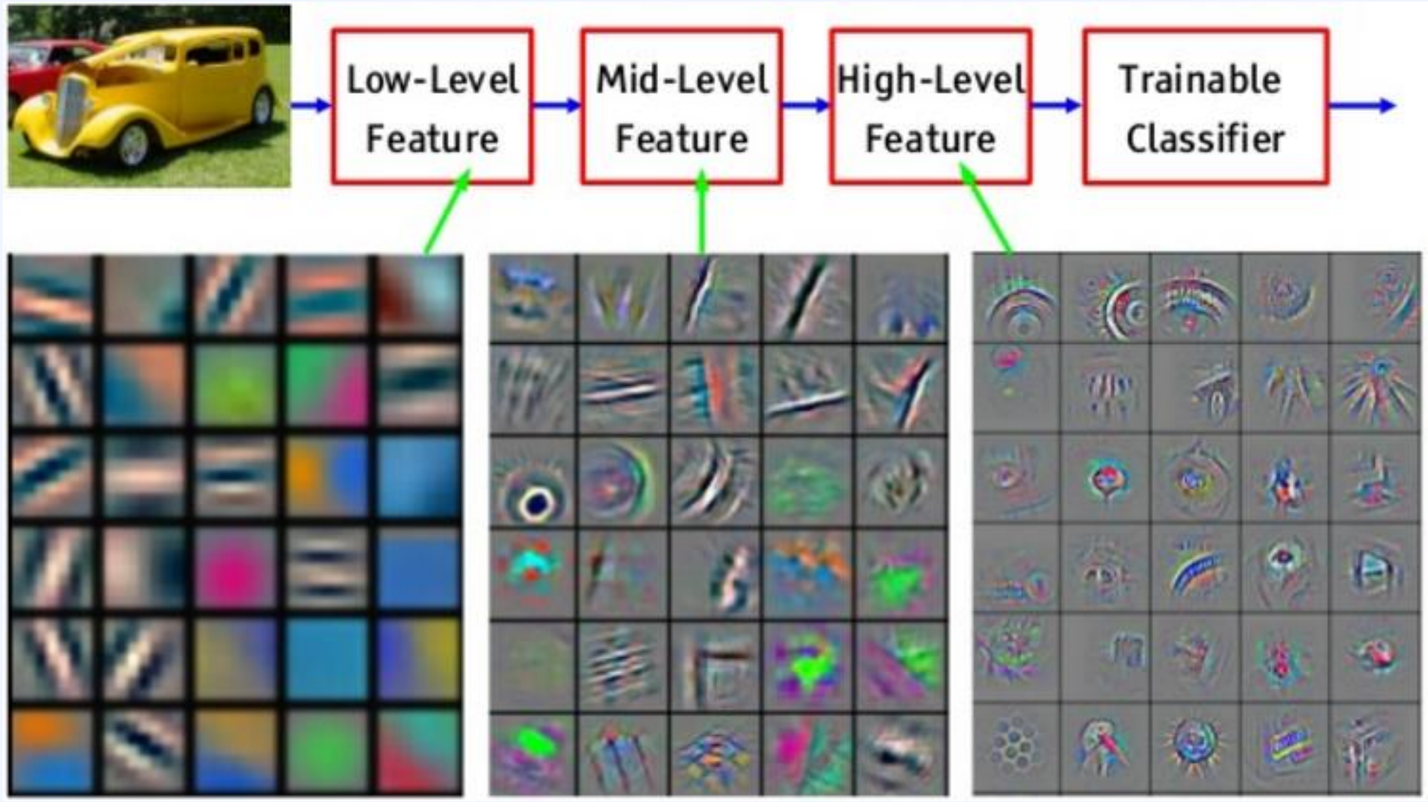

Convolution

➢ Kernel
- Convolution 연산 수행 시 여러 개의 Kernel을 적용하여 다양한 형태의 Feature를 추출

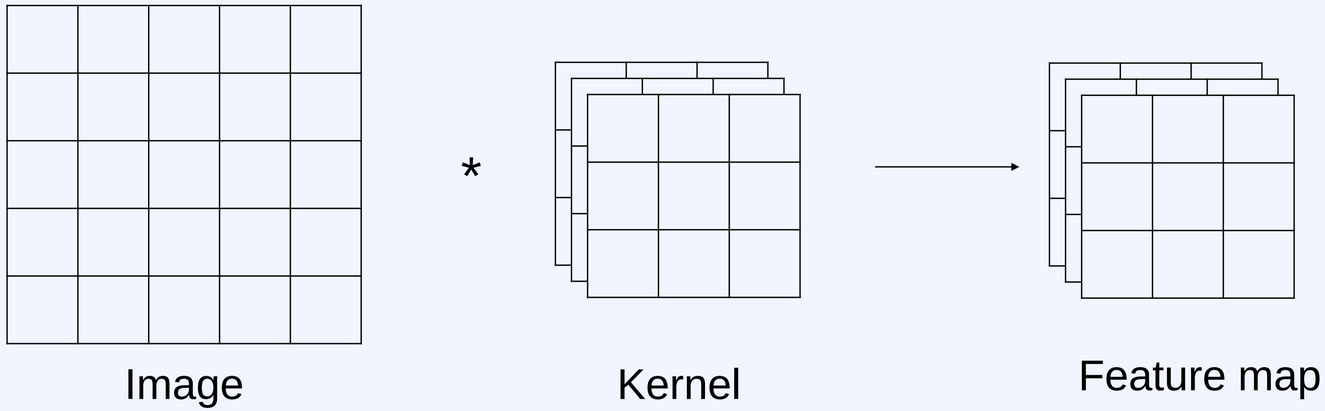

Convolution

- Kernel 그리고 Channel
  - 입력 이미지: 32 x 32 x 3
  - 필터 사이즈: 5 x 5 x 3
  - 서로 다른 필터를 10개 사용: 32 x 32 x 10
    - 32 x 32가 유지되는 이유는 padding

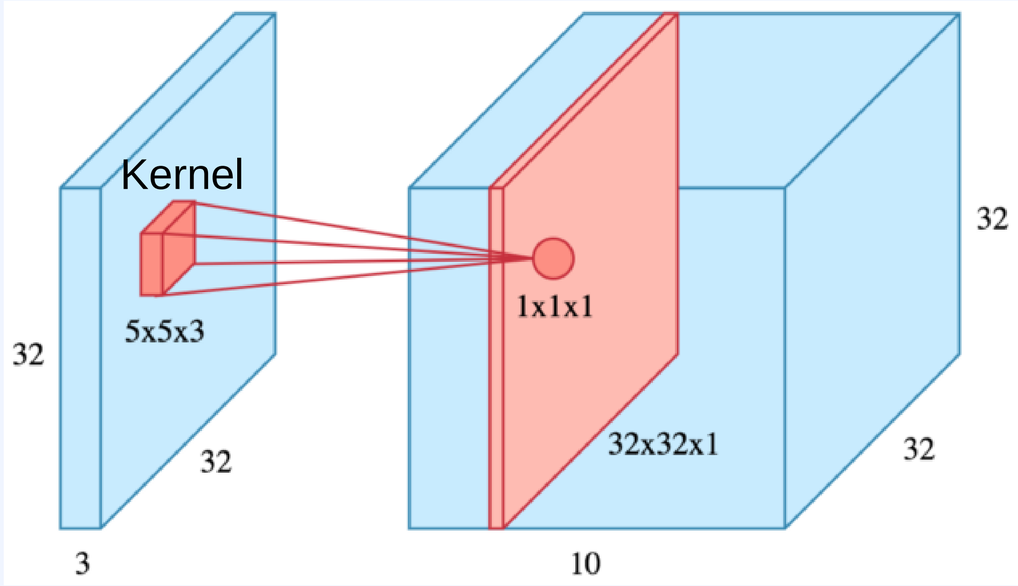

Image Feature map

https://towardsdatascience.com/applied-deep-learning-part-4-convolutional-neural-networks-584bc134c1e2#e865

Convolution

- Padding
  - 원본 이미지 사이즈가 줄어드는 것을 보완

$$o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

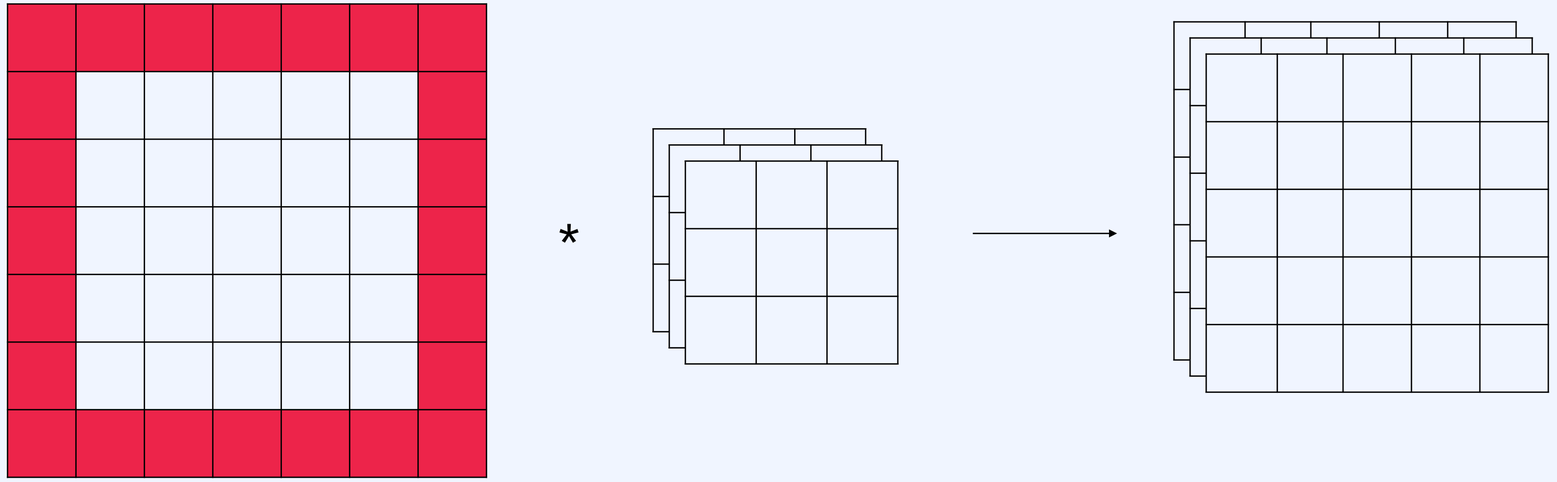

Image　　Kernel　　Feature map

Summary

- 컨볼루션(Convolution)
  - 필터(Filter), 커널(Kernel)
    - 이미지에 겹치는 작은 필터 3x3 또는 5x5 사용
    - 학습을 통해 자동으로 적합한 필터 생성: 이미지의 특징을 추출하는 필터 학습
  - 패딩(Padding)
    - 입력 이미지 주변을 0으로 감싸서, 이미지 크기가 줄어드는 것을 보완
  - 스트라이드(Stride)
    - 필터를 몇 칸 씩 건너뛰며 적용할 지 조절하는 값
  - 특징 맵(feature map)
    - Convolution 연산을 거쳐 나온 새로운 이미지유형

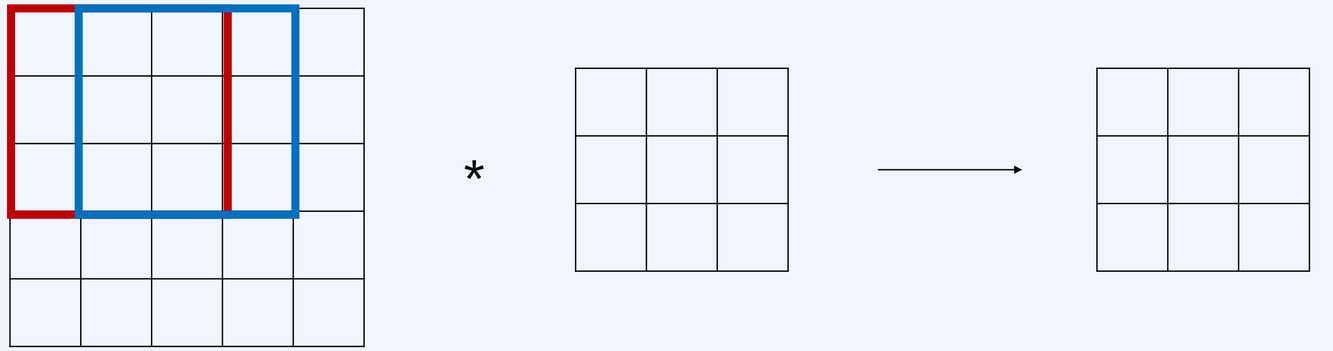

Quiz

Q 다음 중 Convolution 연산의 특징으로 옳지 않은 것은?

① **Convolution은** 합성곱 연산으로 연산 결과 Feature map을 생성한다.

② padding을 적용하면 출력 Feature map의 사이즈가 줄어들지 않는다 .

③ Convolution 연산 수행 시 다양한 특징을 추출할 수 있도록 kernel 값을 설정해야 한다.

④ Convolution 연산을 수행할수록 점점 복잡한 형태의 고차원 특징을 추출할 수 있다.

해설

▶ kernel의 값은 학습을 통해 업데이트되는 값이다.

CNN

Pooling & Fully Connected

Pooling & Fully connected

➢ Image classifier의 구성

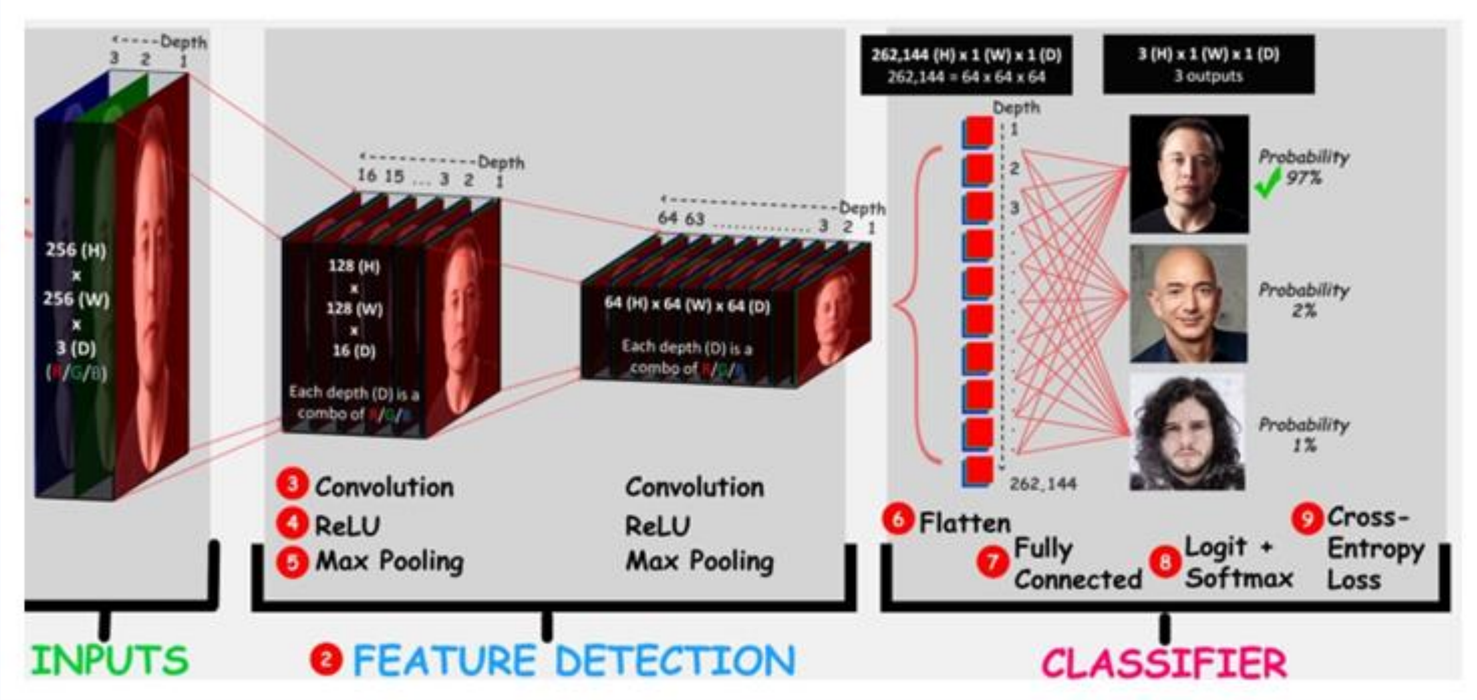

Pooling layer

➢ Pooling
- 필터를 거친 여러 특징 중 가장 중요한 특징 하나를 선택하여 feature 수를 줄임 (Sub-sampling)
- 평균값(average-pooling)이나 최대값(max-pooling) 선택
- 학습해야 할 매개변수가 없고, 채널 수가 변하지 않음

➢ Max pooling

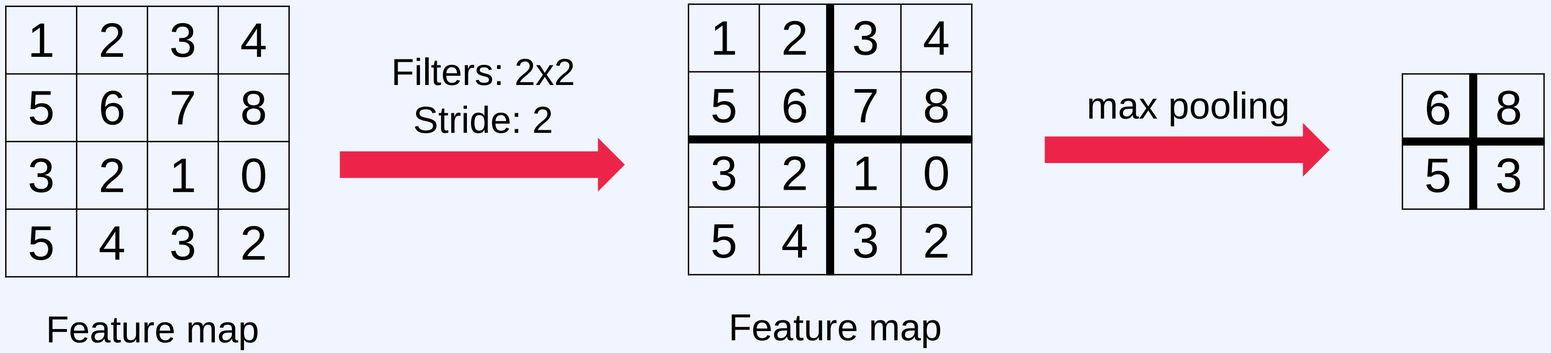

Pooling layer

➢ Pooling
- 필터를 거친 여러 특징 중 가장 중요한 특징 하나를 선택하여 차원을 축소하는 작업 (Sub-sampling)
- 평균값(average pooling)이나 최대값(max-pooling) 선택
- 학습해야 할 매개변수가 없고, 채널 수가 변하지 않음

1	2	3	4
5	6	7	8
3	2	1	0
5	4	3	2

Feature map

Filters: 2x2
Stride: 2

1	2	3	4
5	6	7	8
3	2	1	0
5	4	3	2

Feature map

max pooling

6	8
5	3

$$o = \left\lfloor \frac{i-k}{s} \right\rfloor + 1.$$

Fully Connected layer

- Fully Connected layer
  - 이전 레이어의 모든 처리 결과를 하나로 연결
  - Feature extraction 결과를 바탕으로 이미지를 분류(Classification)
    - output layer는 분류 범주의 개수만큼 노드 설정

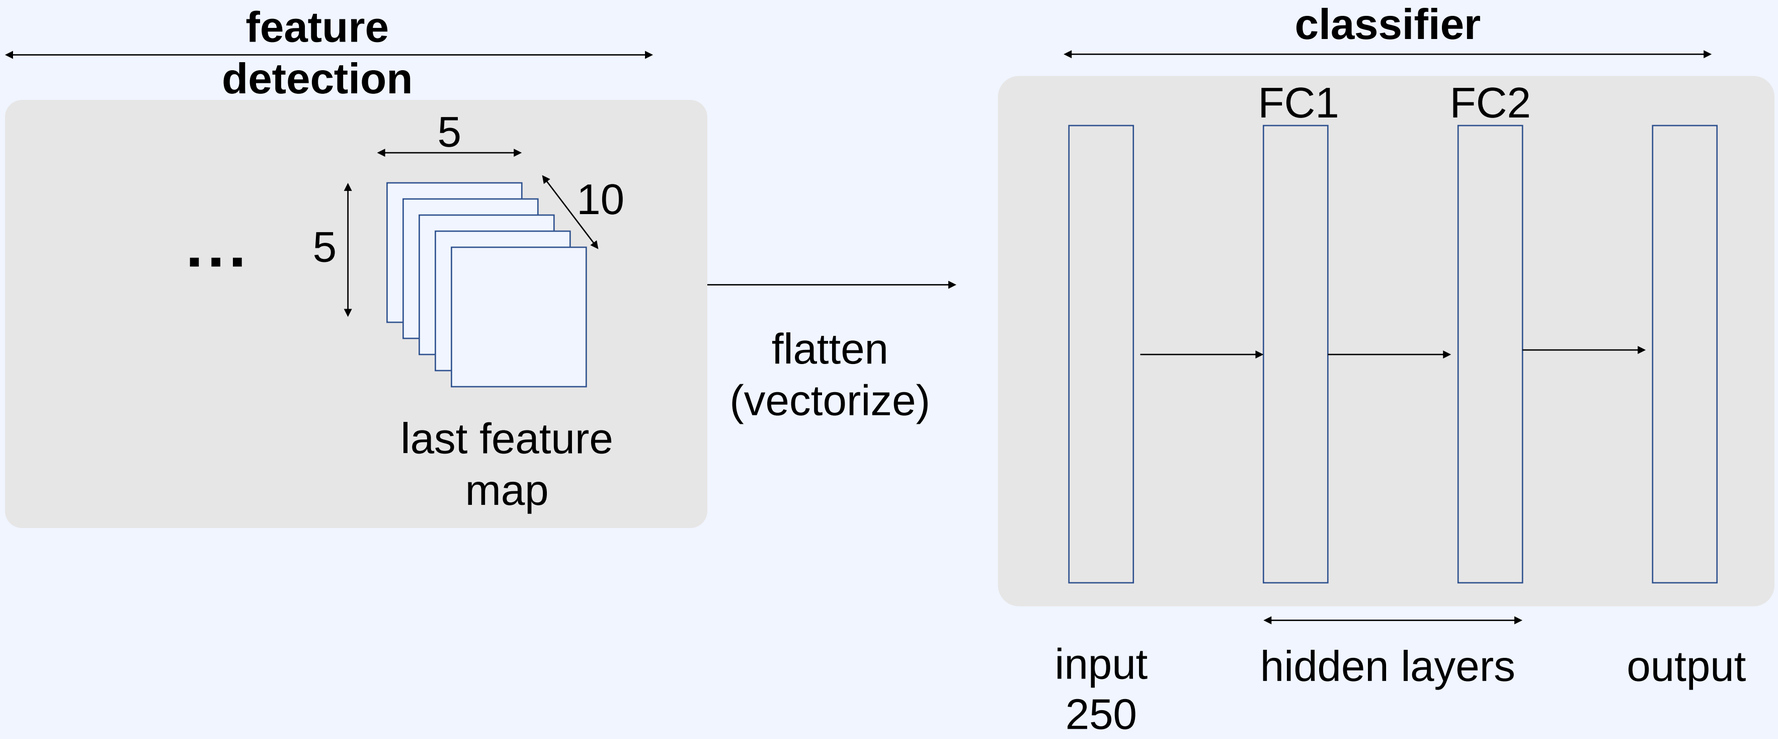

CNN의 하이퍼파라미터

- Convolution Layers
  - Conv layers 개수
  - Filter size : 일반적으로 홀수값을 설정
  - Filters의 개수: Channel 수, 일반적으로 2의 배수로 설정
  - Stride, padding…
- Pooling Layers
  - Pooling layers 개수
  - Pooling windows size
  - Stride
- FC Layers
  - FC layers 개수
  - FC layer를 구성하는 노드의 개수
- 학습을 위한 하이퍼파라이터
  - batch size, epcohs, learning rate, momentum coefficient …

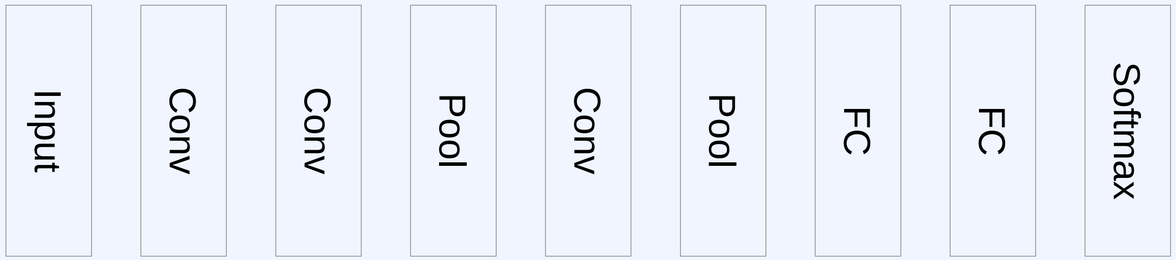

Summary

- Image classifier

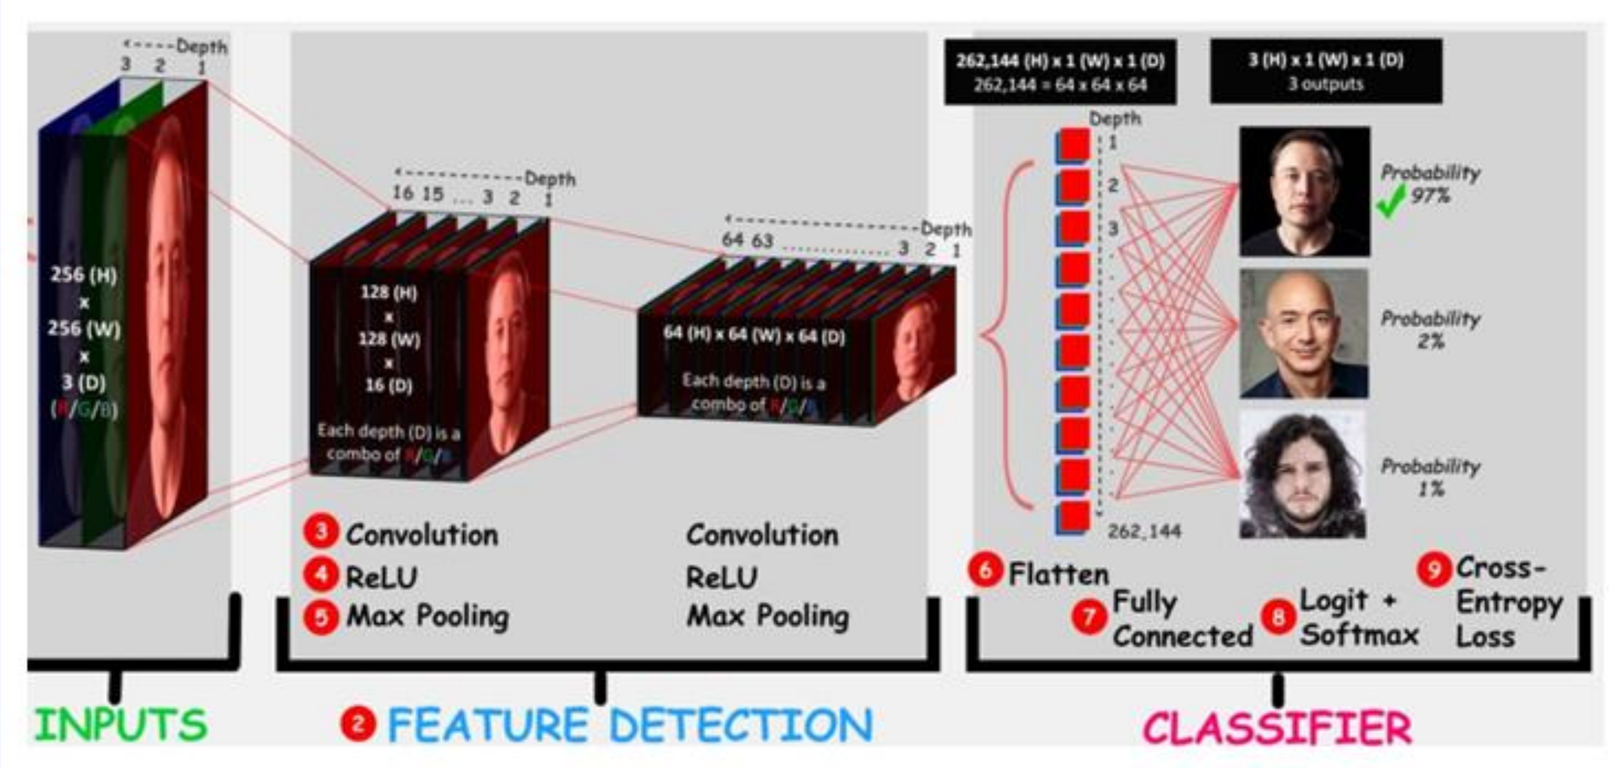

Quiz

Q 다음 CNN에서 수행하는 연산에 대한 설명 중 올바르게 작성된 것은?

① Conv layer 다음에는 반드시 Pooling layer 를 연결해야한다.

② Pooling layer는 학습에 의해서 업데이트 되는 값이 존재하지 않는다.

③ Pooling layer를 통과하고 나면 채널의 수가 감소한다.

④ Feature extraction이 끝나면 Classifier의 역할을 하는 FC layer는 shape 변경없이 연결할 수 있다.

해설

▶ ① Conv layer뒤에 반드시 Pooling layer를 연결할 필요는 없다. ③ Pooling layer를 통과해도 채널의 수는 유지된다. ④ FC layer를 연결하기 위해서 Flatten을 통해 shape을 1차원으로 변경해야한다.

CNN

입출력 크기 및 메모리 사용량 계산

Feature Map Size

- feature map size
  - i : 입력 feature의 수
  - o : 출력 feature의 수
  - k : convolution kernel 사이즈
  - p : convolution padding 사이즈
  - s : convolution stride 사이즈

$$o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

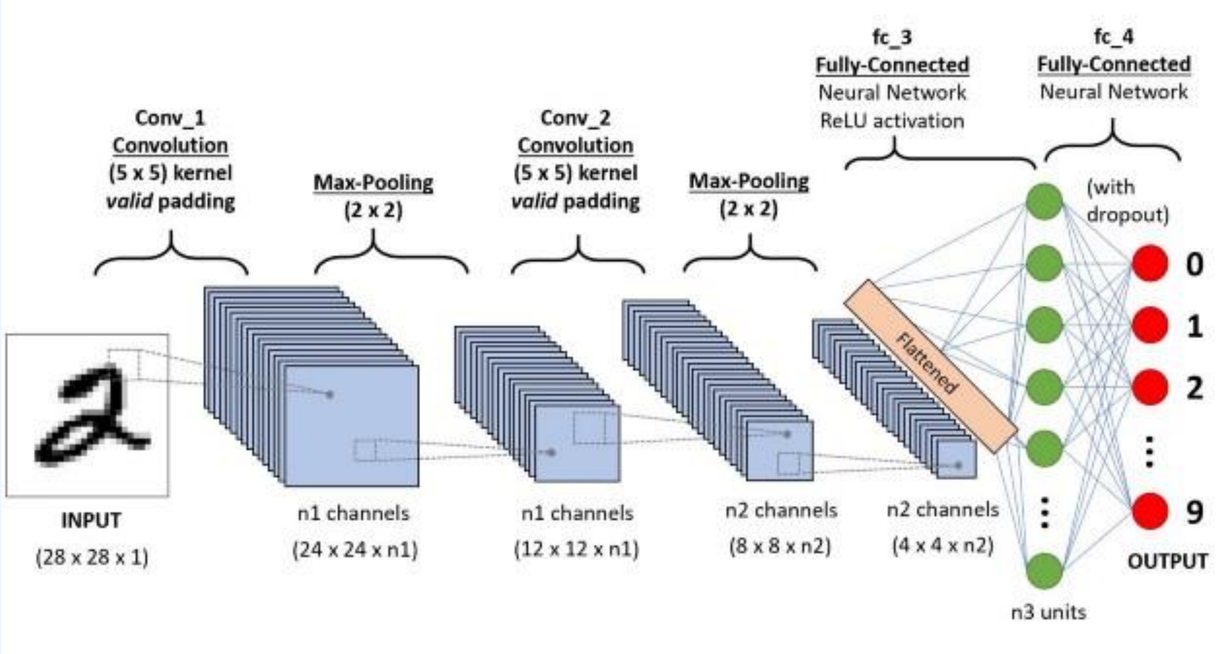

https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53

Feature Map Size

- feature map size
  - i : 입력 feature의 수 $\rightarrow 7$
  - o : 출력 feature의 수
  - k : convolution kernel 사이즈 $\rightarrow 3$
  - p : convolution padding 사이즈 $\rightarrow 0$
  - s : convolution stride 사이즈 $\rightarrow 1$

$$o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

$$= \left\lfloor \frac{7 + 2 \times 0 - 3}{1} \right\rfloor + 1$$

$$= 5$$

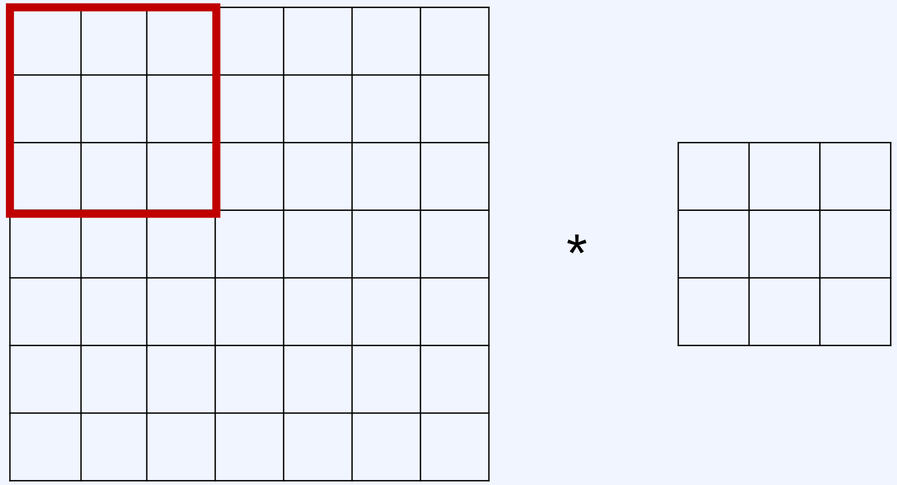

Feature Map Size

➢ stride 값을 늘리면?

- 연산량이 줄어든다.
- 출력 feature의 수가 줄어든다.
- 정보의 손실이 발생한다.

$$o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

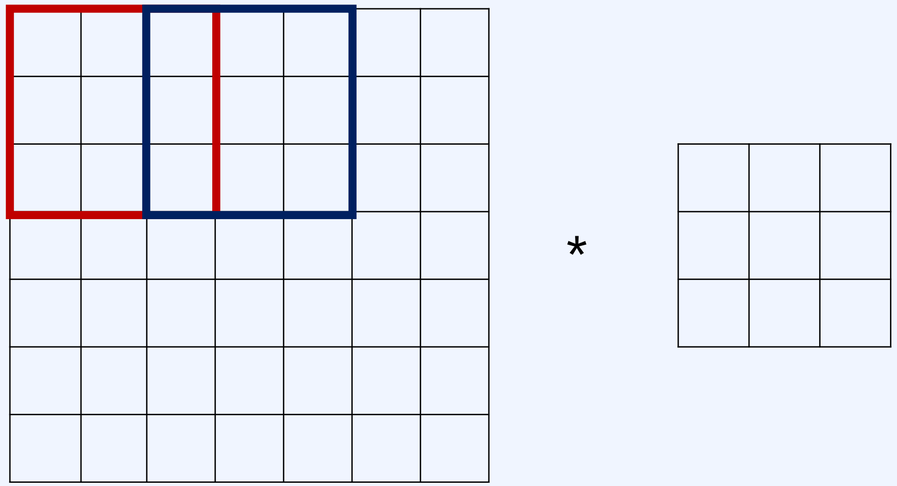

Feature Map Size

- padding을 1보다 큰 값으로 설정하면?
  - feature의 수가 줄어드는 것을 막을 수 있다.

$$o = \left\lfloor \frac{i + 2p - k}{s} \right\rfloor + 1$$

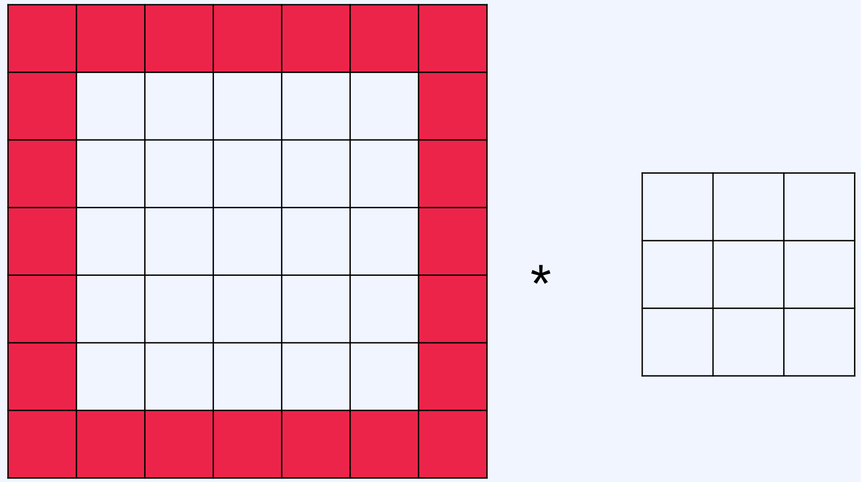

Storage Complexity - Weight 수

➢ **layer i의 가중치(weights) 수 =** 학습을 통해 업데이트 되는 파라미터의 수 = $(\mathbf{k} \times \mathbf{k} \times \mathbf{c_{i-1}}) \times \mathbf{c_i}$

- k : filter size
- c_{i-1} : 이전 레이어의 채널의 수
- c_i : 현재 레이어의 채널의 수

➢ 신경망 학습 이후 메모리에 저장되는 값

- storage complexity

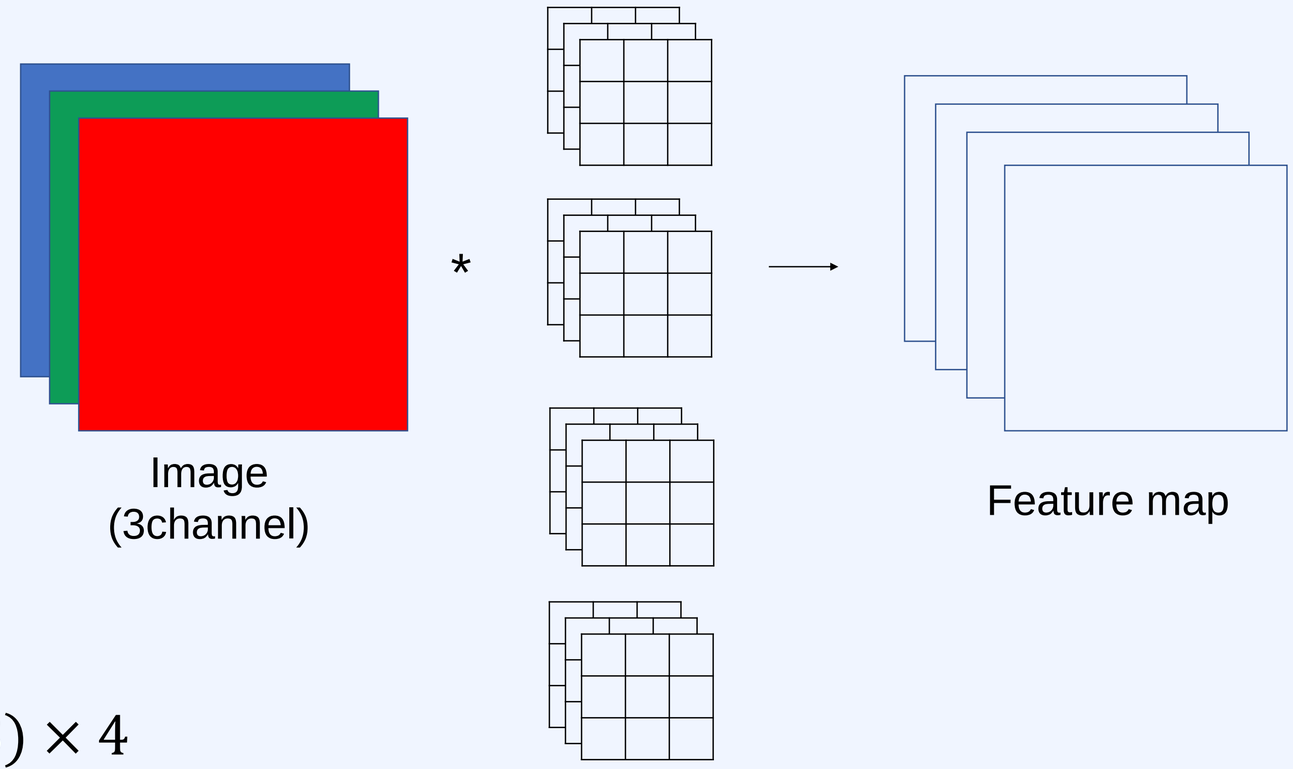

$$(k \times k \times c_{i-1}) \times c_i = (3 \times 3 \times 3) \times 4$$

Storage Complexity – memory

- **layer i의 메모리 = 학**습 결과 $= (\boldsymbol{m_i} \times \boldsymbol{m_i}) \times \boldsymbol{c_i}$
  - m_i : 현재 레이어의 feature map 사이즈
  - c_i : 현재 레이어의 채널의 수

- 추론 과정에서의 메모리가 소요되는 정도
  - run time

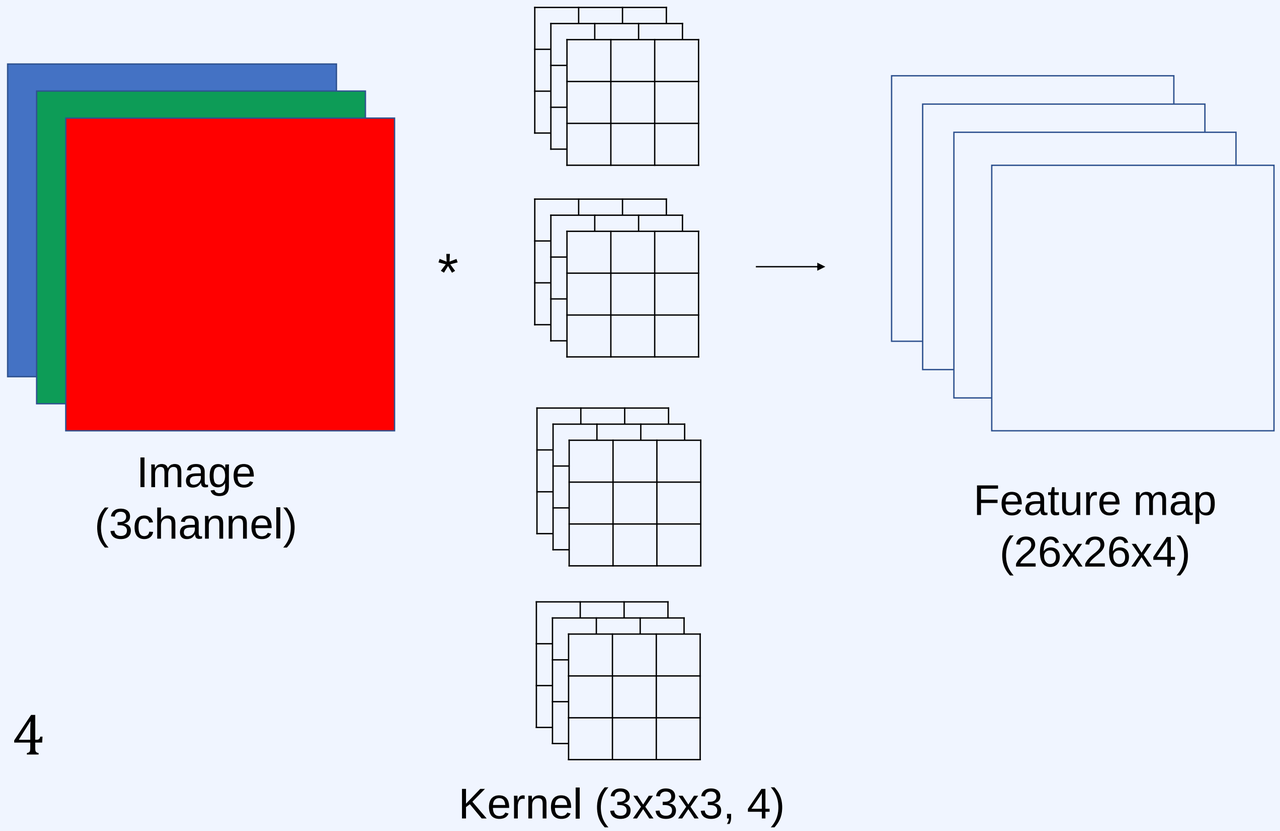

$$(\boldsymbol{m_i} \times \boldsymbol{m_i}) \times \boldsymbol{c_i} = (26 \times 26) \times 4$$

Computational Complexity

- **layer i의 계산 복잡도** $= (\mathbf{k} \times \mathbf{k}) \times (\boldsymbol{m}_{\mathbf{i}} \times \boldsymbol{m}_{\mathbf{i}}) \times (\mathbf{c}_{\mathbf{i-1}} \times \mathbf{c}_{\mathbf{i}})$
  - k : filter size
  - m_i : 현재 레이어의 feature map 사이즈
  - c_{i-1} : 이전 레이어의 채널의 수
  - c_i : 현재 레이어의 채널의 수

- 추론 과정에서 계산 복잡도 결정
  - 학습 과정에는 GPU등 하드웨어 리소스를 사용할 수 있으므로 계산 복잡도는 큰 고려요소는 아님
  - # Conv Ops (FLOPs, floating point operation)

VGGNet

➢ representation size and the total number of weights:

INPUT: [224x224x3] memory: 224*224*3=150K weights: 0
CONV3-64: [224x224x64] memory: 224*224*64=3.2M weights: (3*3*3)*64 = 1,728
CONV3-64: [224x224x64] memory: 224*224*64=3.2M weights: (3*3*64)*64 = 36,864
POOL2: [112x112x64] memory: 112*112*64=800K weights: 0
CONV3-128: [112x112x128] memory: 112*112*128=1.6M weights: (3*3*64)*128 = 73,728
CONV3-128: [112x112x128] memory: 112*112*128=1.6M weights: (3*3*128)*128 = 147,456
POOL2: [56x56x128] memory: 56*56*128=400K weights: 0
CONV3-256: [56x56x256] memory: 56*56*256=800K weights: (3*3*128)*256 = 294,912
CONV3-256: [56x56x256] memory: 56*56*256=800K weights: (3*3*256)*256 = 589,824
CONV3-256: [56x56x256] memory: 56*56*256=800K weights: (3*3*256)*256 = 589,824
POOL2: [28x28x256] memory: 28*28*256=200K weights: 0
CONV3-512: [28x28x512] memory: 28*28*512=400K weights: (3*3*256)*512 = 1,179,648
CONV3-512: [28x28x512] memory: 28*28*512=400K weights: (3*3*512)*512 = 2,359,296
CONV3-512: [28x28x512] memory: 28*28*512=400K weights: (3*3*512)*512 = 2,359,296
POOL2: [14x14x512] memory: 14*14*512=100K weights: 0
CONV3-512: [14x14x512] memory: 14*14*512=100K weights: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K weights: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K weights: (3*3*512)*512 = 2,359,296
POOL2: [7x7x512] memory: 7*7*512=25K weights: 0
FC: [1x1x4096] memory: 4096 weights: 7*7*512*4096 = 102,760,448
FC: [1x1x4096] memory: 4096 weights: 4096*4096 = 16,777,216
FC: [1x1x1000] memory: 1000 weights: 4096*1000 = 4,096,000

TOTAL memory: 24M * 4 bytes ~= 93MB / image (only forward! ~*2 for bwd)
TOTAL params: 138M parameters

https://cs231n.github.io/convolutional-networks/

Summary

- Feature Map Size

$$o = \left\lfloor \frac{i + 2p \ - k}{s} \right\rfloor + 1$$

- layer i의 가중치(weights) 수 = 학습을 통해 업데이트 되는 파라미터의 수 = $(\mathbf{k} \times \mathbf{k} \times \mathbf{c_{i-1}}) \times \mathbf{c_i}$

- layer i의 메모리 = 학습 결과 = $(\boldsymbol{m_i} \times \boldsymbol{m_i}) \times \mathbf{c_i}$

- layer i의 계산 복잡도 $= (\mathbf{k} \times \mathbf{k}) \times (\boldsymbol{m_i} \times \boldsymbol{m_i}) \times (\mathbf{c_{i-1}} \times \mathbf{c_i})$

Quiz

Q 다음 설명 중 옳지 않은 것은?

① padding을 1보다 큰 값으로 설정하면 feature의 수가 줄어드는 것을 막을 수 있다.

② stride 값을 늘리면 연산량이 줄어들지만, 정보의 손실이 발생한다.

③ 신경망의 Computational Complexity는 학습 과정 시 고려해야한다.

④ 신경망을 구성하는 가중치는 학습 이후 저장 공간에 저장되는 값이다.

해설

▶ 신경망의 Computational Complexity는 추론 과정 시 고려해야한다.

CNN

VGGNet

ILSVRC

- 이미지 넷(Image Net)의 사물 인식 대회(Large Scale Visual Recognition Challenge)
- ILSVRC 대회 역대 우승 알고리즘

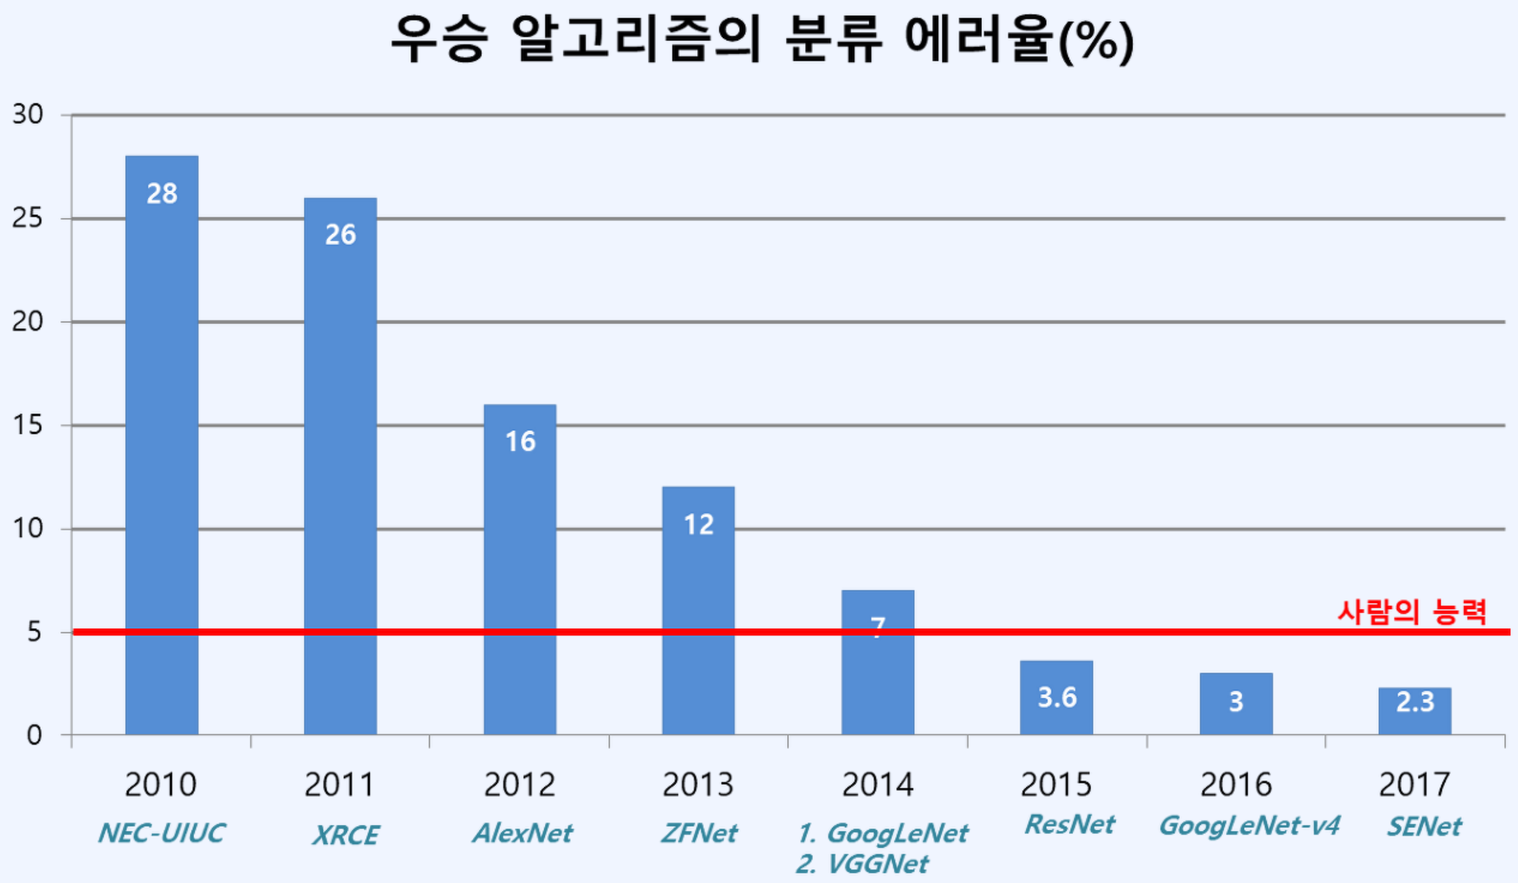

VGGNet

- 2014년 이미지 사물인식 대회에서 2위(1위는 GoogLeNet)
- Paper
  - Karen Simonyan, Andrew Zisserman. University of Oxford, UK. **Very Deep Convolutional Networks for Large-Scale Image Recognition**, arXiv preprint, 2014
- VGGNet-16
  - 13 conv layers + 3 FC
  - 138 Million weights and 500MB of storage space in total!
  - 변형: VGGNet-19

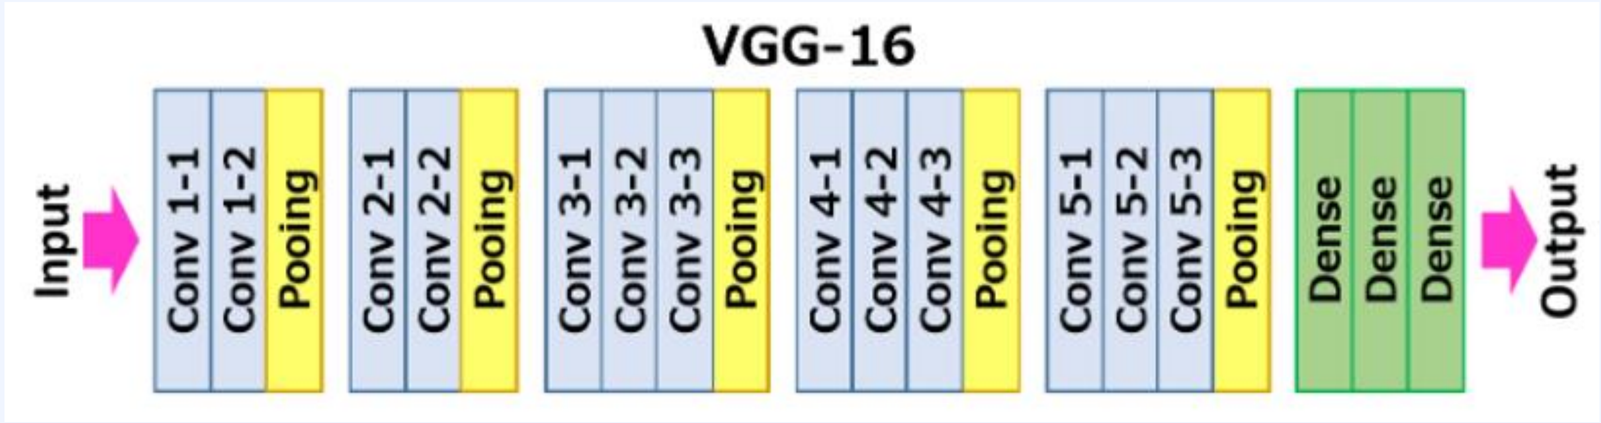

VGGNet

- VGGNet 이전에 나왔던 AlexNet의 경우에는 첫번째 Conv layer에 11x11 필터를 사용
- VGGNet의 가장 큰 특징!
  - 3x3 필터만 사용해도 충분하다는 것을 보여줌

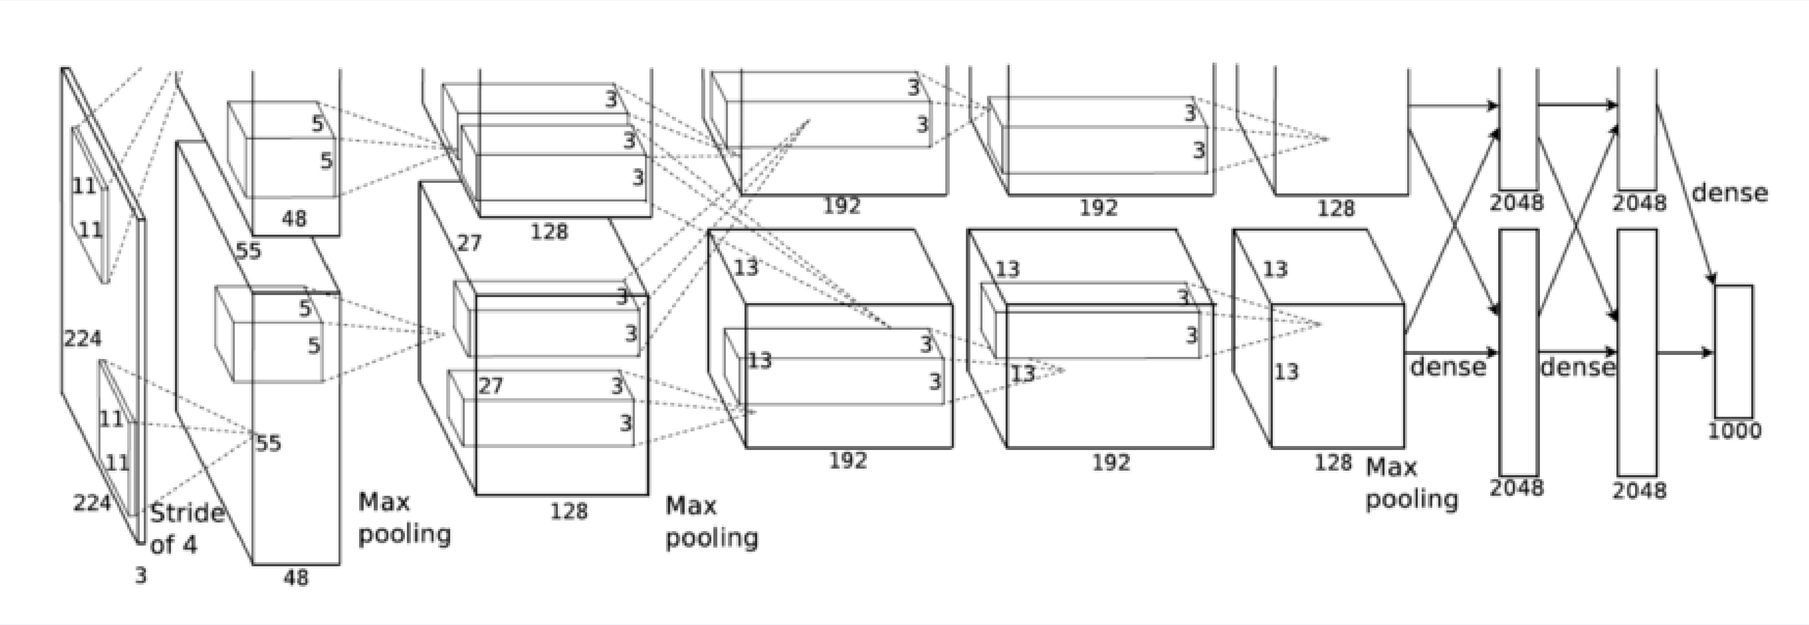

AlexNet

VGGNet

- Local Connectivity
  - Receptive Field(RF)
  - kernel이 convolution 연산을 수행할 때 이미지의 얼마나 많은 영역을 수용할 수 있는가?

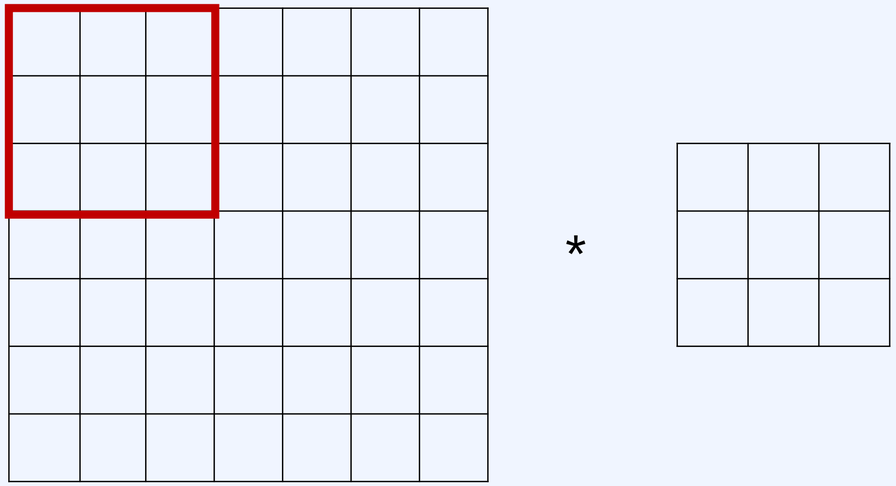

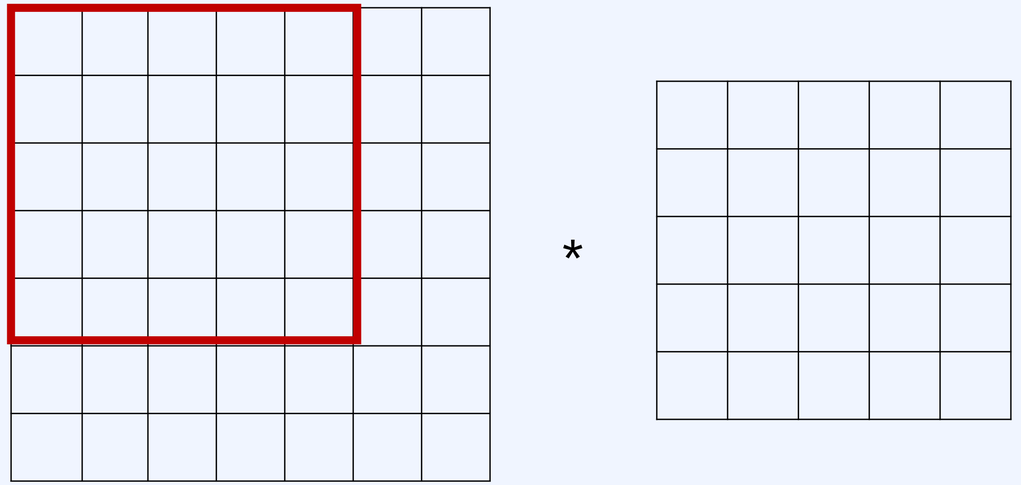

VGGNet

- Local Connectivity
  - Receptive Field(RF)
    - Convolution 연산을 수행할 수록 RF가 더 커짐

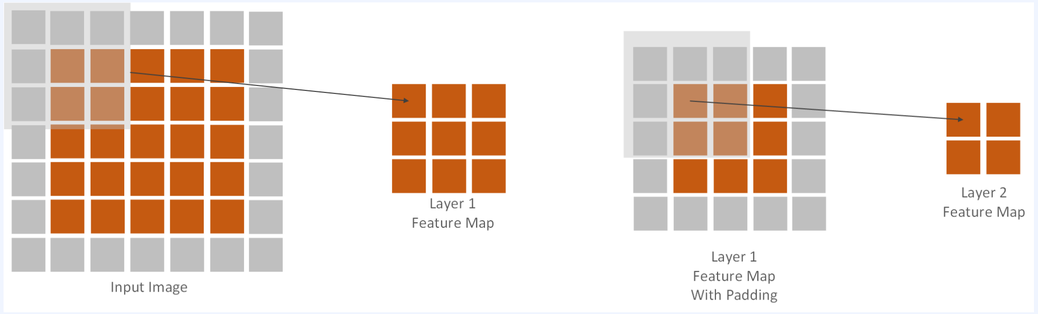

$$r_i = r_{i-1} + (k-1)\prod_{k=1}^{i-1} s_k$$

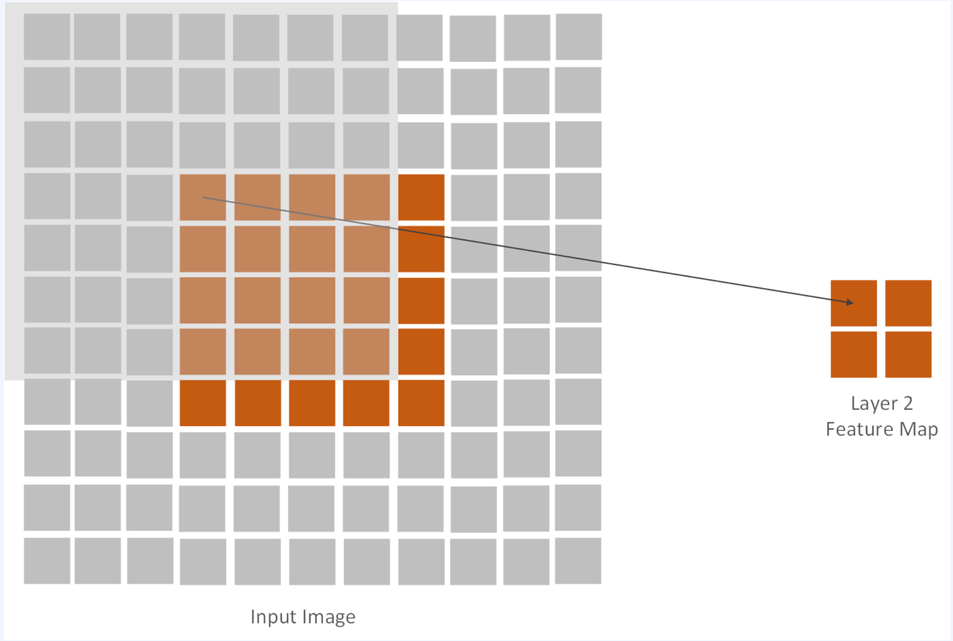

https://rubikscode.net/2021/11/15/receptive-field-arithmetic-for-convolutional-neural-networks/

VGGNet

- 7x7 커널을 하나만 사용한 경우 vs 3x3 커널을 3번 사용한 경우
  - 동일한 효과를 갖는다
  - Conv 연산의 횟수가 증가하는데 사용하는 메모리가 늘어나는 단점이 있지 않을까?

$$r_i = r_{i-1} + (k-1)\prod_{k=1}^{i-1} s_k$$

	7x7 필터 한 번	3x3 필터 세 번
Receptive Field	$R_1 = k = 7$	$R_1 = k = 3$ $R_2 = R_1 + (3-1) = 3 + 2 = 5$ $R_3 = R_2 + (3-1) = 5 + 2 = 7$

VGGNet

➢ 5x5 필터를 사용하는 경우

- layer i의 가중치(weights) 수 = 학습을 통해 업데이트 되는 파라미터의 수 = $(\mathbf{k} \times \mathbf{k} \times \mathbf{c_{i-1}}) \times \mathbf{c_i}$
  - k : filter size
  - c_{i-1} : 이전 레이어의 채널의 수
  - c_i : 현재 레이어의 채널의 수

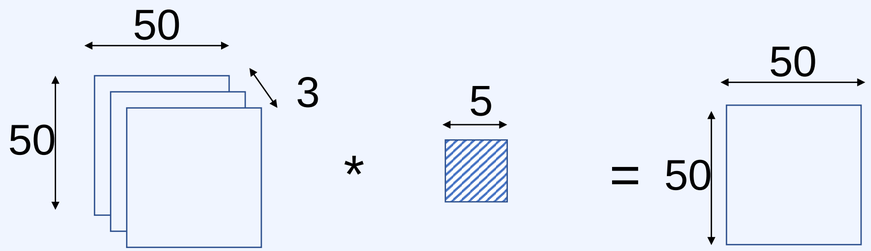

Input Image

5x5 필터 사용
(c_2 = 1)인 경우

2번째 레이어의 weight의 수
= $(k \times k \times c_1) \times c_2 = (5 \times 5 \times 3) \times 1 = 75$

VGGNet

➢ 3x3 필터를 두 번 사용하는 경우

- layer i의 가중치(weights) 수 = 학습을 통해 업데이트 되는 파라미터의 수 = $(\mathbf{k} \times \mathbf{k} \times \mathbf{c_{i-1}}) \times \mathbf{c_i}$
  - k : filter size
  - c_{i-1} : 이전 레이어의 채널의 수
  - c_i : 현재 레이어의 채널의 수

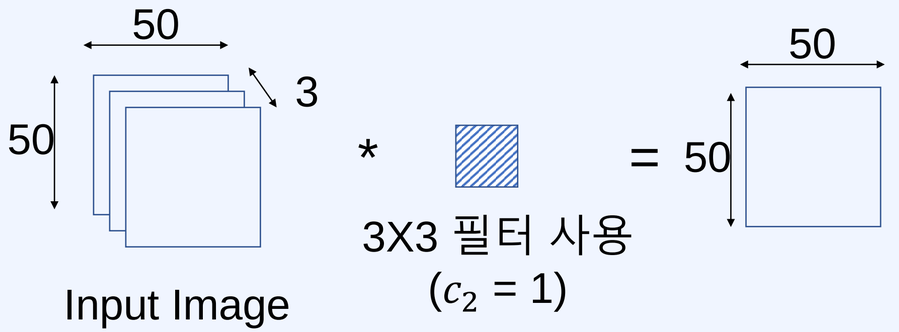

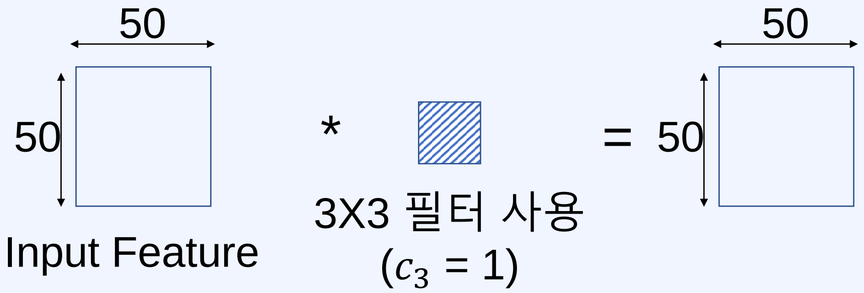

2번째 레이어의 weight의 수
$= (k \times k \times c_1) \times c_2 = (3 \times 3 \times 3) \times 1 = 27$

3번째 레이어의 weight의 수
$= (k \times k \times c_2) \times c_3 = (3 \times 3 \times 1) \times 1 = 9$

총 weight의 수 = 36

VGGNet

➢ 5x5 필터를 사용하는 경우 vs 3x3 필터를 두 번 사용하는 경우

	5x5 필터 한 번	3x3 필터 두 번
총 weight의 수	75	36
Activation Function	1	2
Receptive Filed	$R_1 = k = 5$	$R_1 = k = 3$ $R_2 = R_1 + (3-1) = 3 + 2 = 5$

➢ 동일한 Receptive Filed!

➢ Weight의 수는 줄어든다
- 메모리 사용량이 감소함

➢ 더 많은 Activation Function을 통과한다
- 비선형성이 증가함

Summary

➢VGGNet

- 3x3 Convolution 연산을 여러 번 사용했을 때의 효과

  ①Receptive Filed를 늘리는 효과

  ②큰 사이즈의 Kernel을 사용했을 때 보다 Weight의 수는 줄어든다: 메모리 사용량이 감소함

  ③더 많은 Activation Function을 통과한다: 비선형성이 증가함

Quiz

Q 다음 중 VGGNet의 특징으로 옳지 않은 것은?

① 2014년 LSVRC 2위를한 16층 구조의 신경망이다.

② 3×3 크기의 필터를 사용해서 특징을 추출하는 구조를 가지고 있다.

③ 3 X 3 크기의 필터를 여러 번 사용할 경우, Receptive Filed를 확장하는 장점이 존재하지만 필요한 메모리 사이즈가 증가한다.

④ Convolution 연산을 여러 번 수행하기 때문에 비선형성을 늘려서 분류의 정확도를 높일 수 있다.

해설

▶ Receptive Filed를 확장할 뿐만 아니라 메모리량도 감소하는 장점이 있다.

CNN

GoogLeNet(Inception)

GoogLeNet(Inception V1)

- 2014년 LSVRC 1위
- Paper
  - Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, Andrew Rabinovich. Google, University of Michigan, University of North Carolina, **Going Deeper with Convolutions**, 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)
  - 22층짜리 신경망, 인셉션 모듈

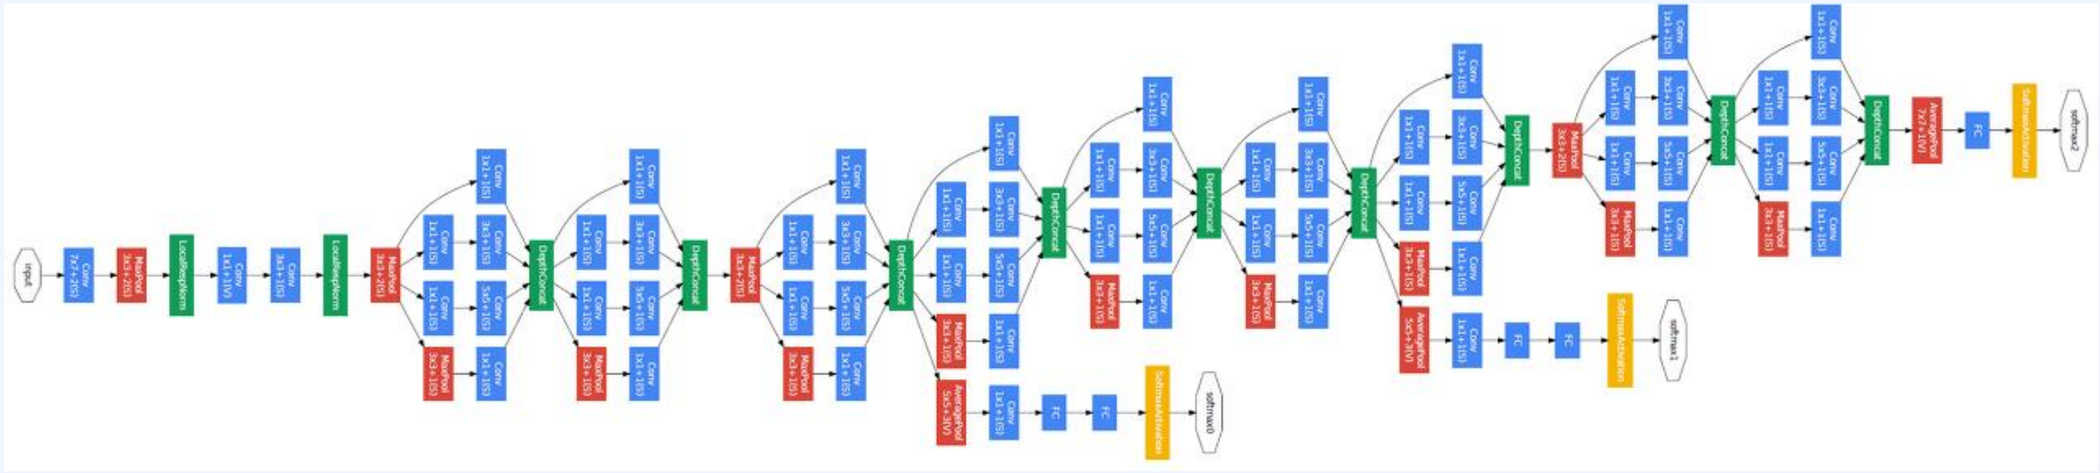

GoogLeNet(Inception V1)

- 22 layers
  - 9개의 Inception 모듈(개별적인 레이어는 100 layers 이상)
  - 5 Million weights in total

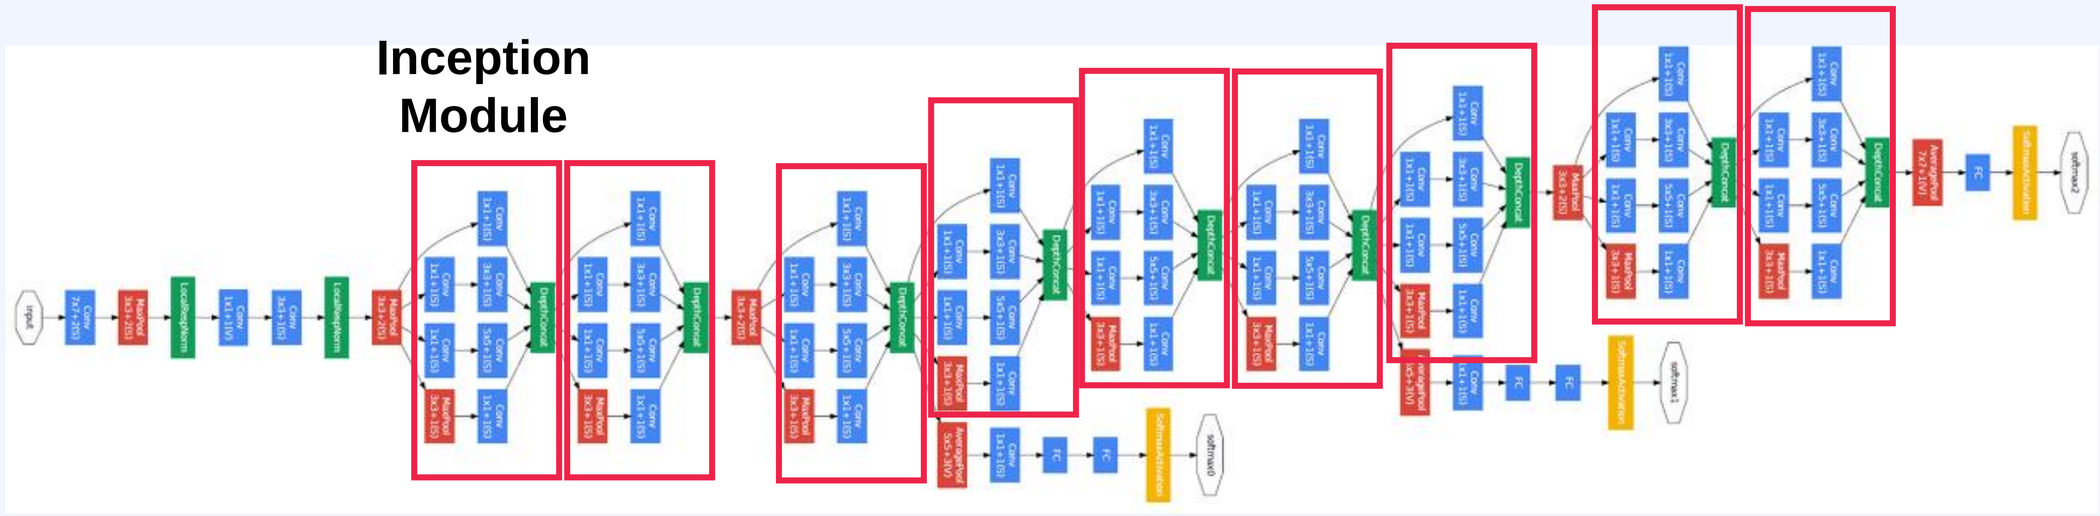

GoogLeNet(Inception V1)

➢ Inception module

- split-transform-merge strategy
  - 다양한 크기의 필터를 사용해서 다양한 특징을 추출
  - 1×1, 3×3, 5×5 kernels

- Bottleneck structure
  - 1x1 Conv: 필터의 크기가 1
  - Dimensionality Reduction 효과
    - 입력의 필터 크기 보다 Conv의 필터 수가 작을 때
    - 연산량을 줄이고, 신경망을 더욱 깊게 쌓을 수 있음
  - 비선형성(nonlinearity) 증가

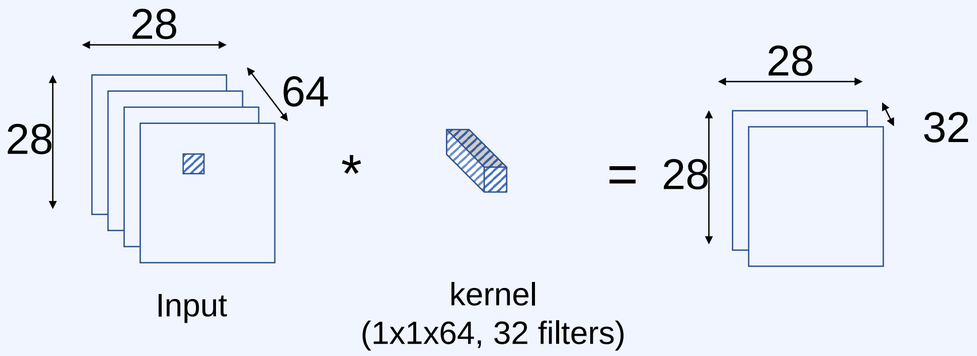

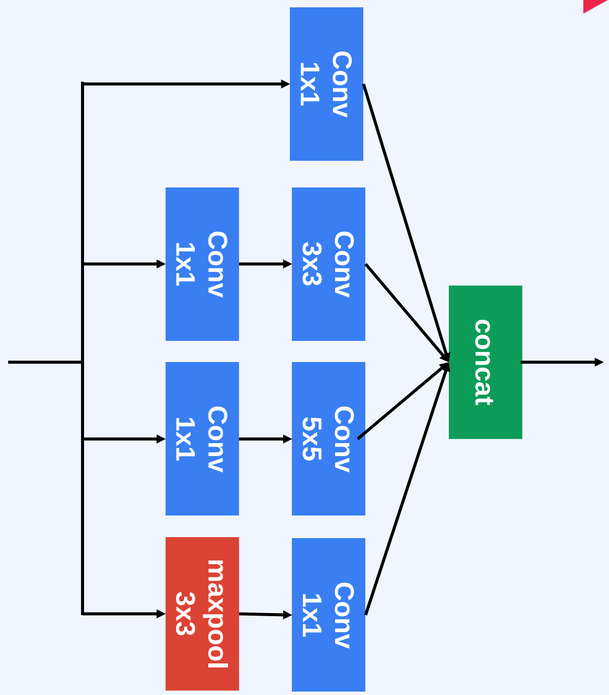

GoogLeNet(Inception V1)

➢ Memory(# of neurons)

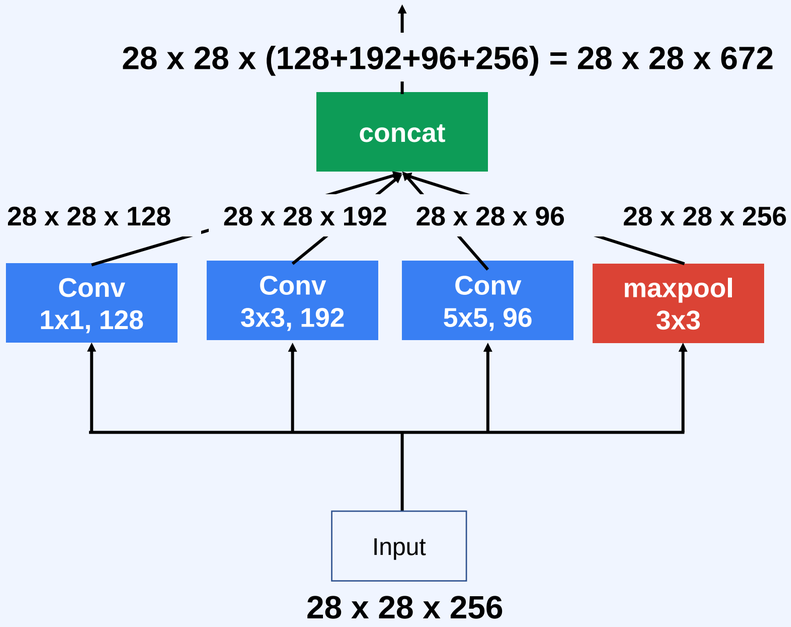

Naïve Inception

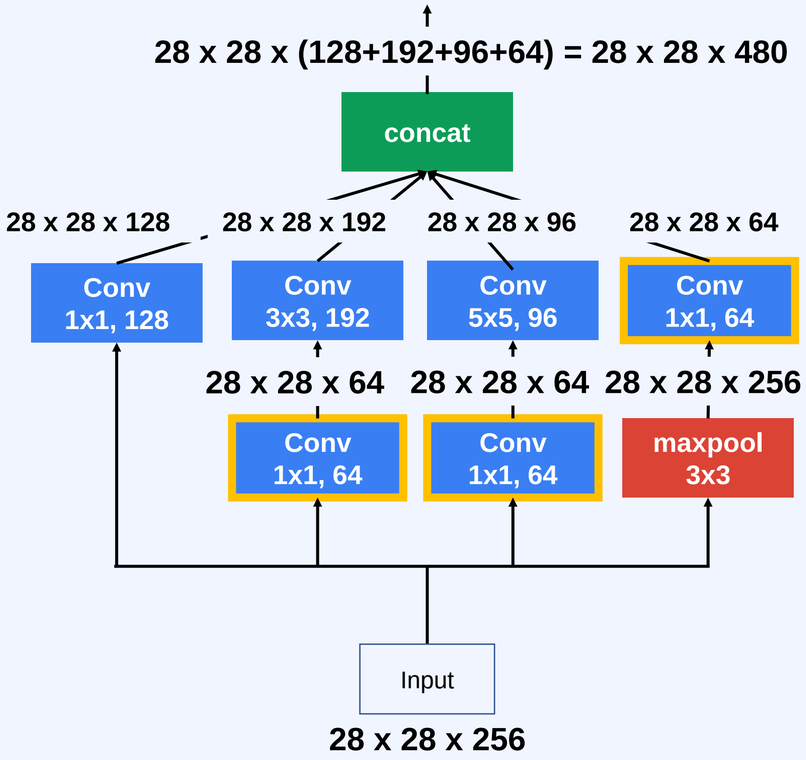

Inception with bottleneck structure

GoogLeNet(Inception V1)

➢ Conv Ops = $(k \times k) \times (\mathrm{m_i} \times m_i) \times (\mathrm{c_{i-1}} \times \mathrm{c_i})$

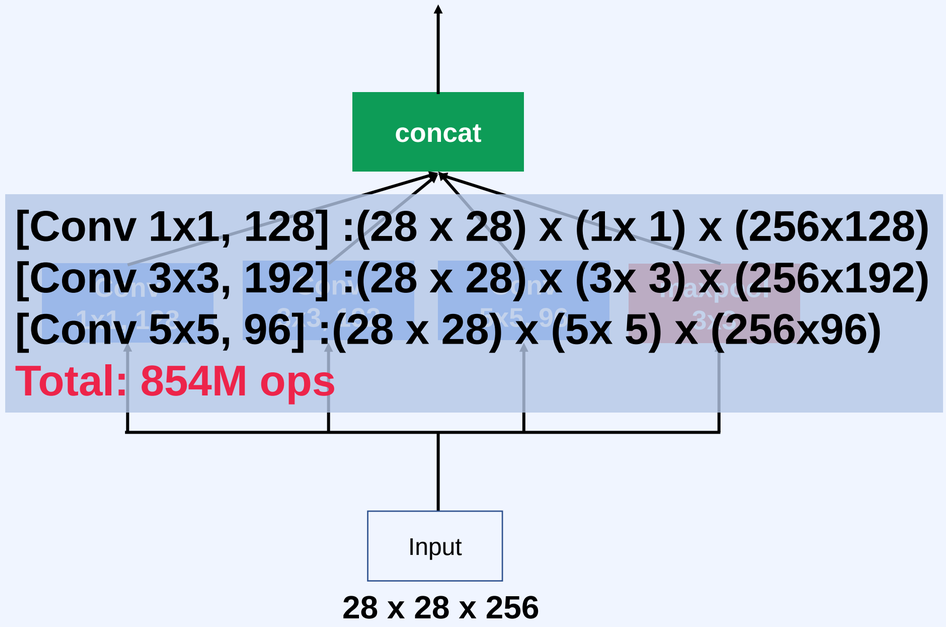

Naïve Inception

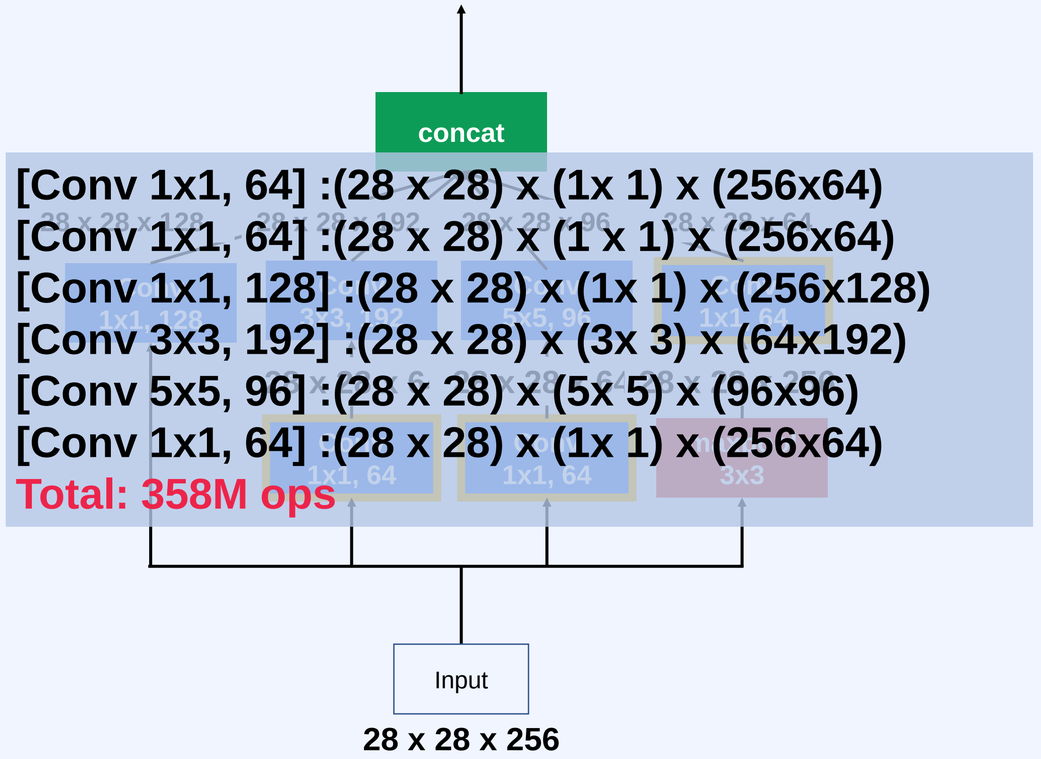

Inception with bottleneck structure

GoogLeNet(Inception V1)

➢ 학습 보조기(auxiliary classifiers)
- 역전파 신호를 잘 전달하기 위해 학습 시 사용하는 모듈
- 학습 이후 추론 단계에서는 사용하지 않음

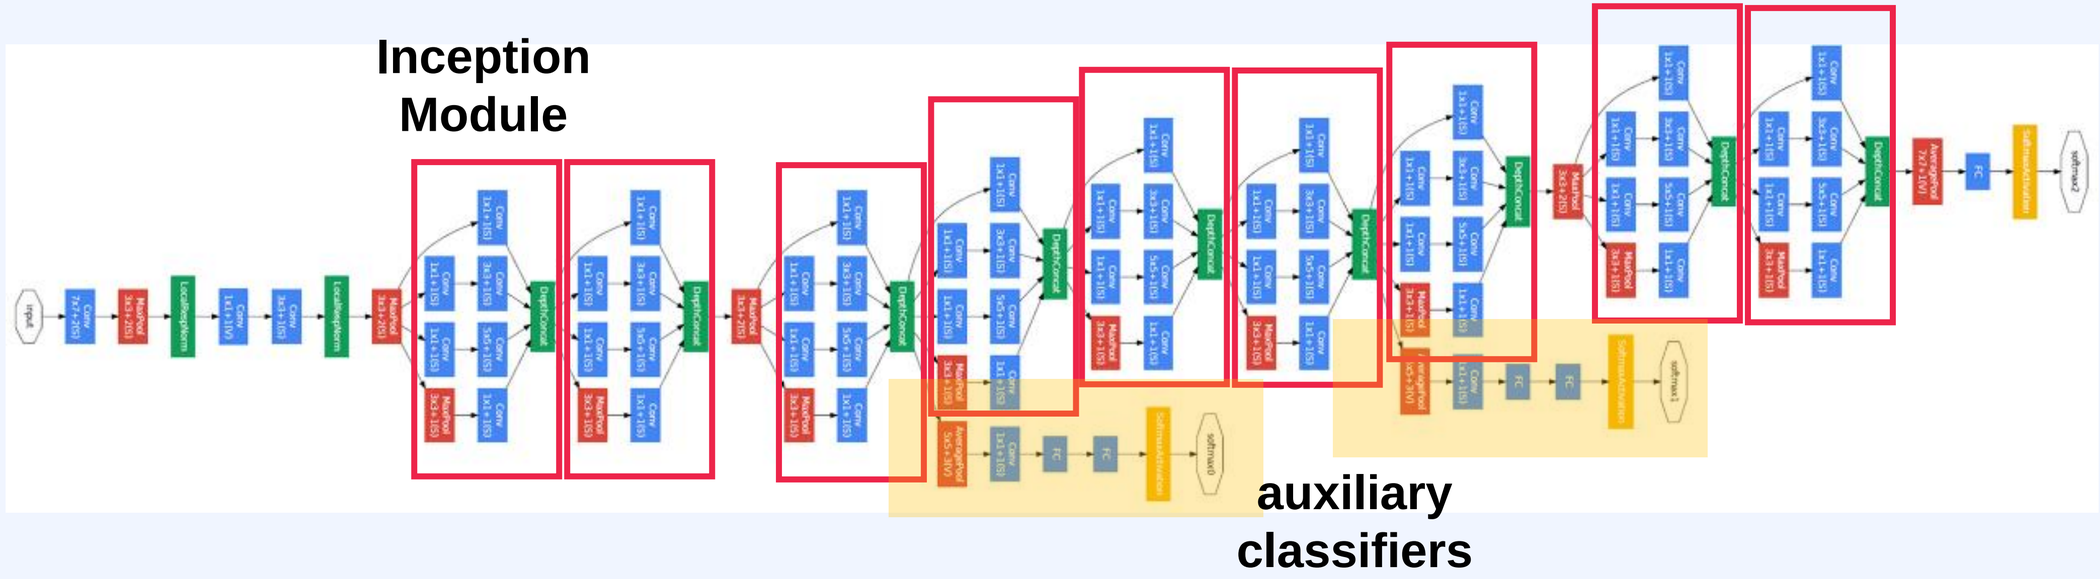

Summary

➢GoogLeNet(Inception V1)

- Inception
  - Parallel filters concatenation + Bottleneck architecture
- 가중치의 수를 줄임
- 비선형성을 증가시킴
- 모델 구성의 새로운 패러다임
  - 단순히 layer를 쌓아 올리는 구조가 아닌, 모듈/블록 구조를 사용

Quiz

Q 다음 중 GoogLeNet의 특징으로 옳지 않은 것은?

① 2014년 LSVRC 1위를한 22층 구조의 신경망이다.

② 1×1, 3×3, 5×5의 다양한 크기의 필터를 사용해서 특징을 추출하는 구조를 가지고 있다.

③ 인셉션 모듈의 1x1 커널은 연산량을 줄이고, 신경망을 더욱 깊게 쌓을 수 있게 한다.

④ GoogLeNet은 인셉션 구조를 사용하여 100층의 깊은 층을 쌓았음에도 불구하고 기울기 소멸 없이 역전파를 할 수 있다.

해설

▶ GooLeNet은 역전파 신호를 잘 전달하기 위해 학습 보조기(auxiliary classifiers)를 사용하여 학습 시 사용했다.

CNN

ResNet

ResNet

- 2015년 LSVRC 1위
- Paper
  - Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. Microsoft**, Deep Residual Learning for Image Recognition,** 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)
- 깊은 신경망(152 layers…) 학습이 가능하게 하는 skip connections 구조
- Batch Normalization을 적용
- 분류기 학습을 위한 FC를 구현하지 않고, GAP(Global Average Pooling)을 수행

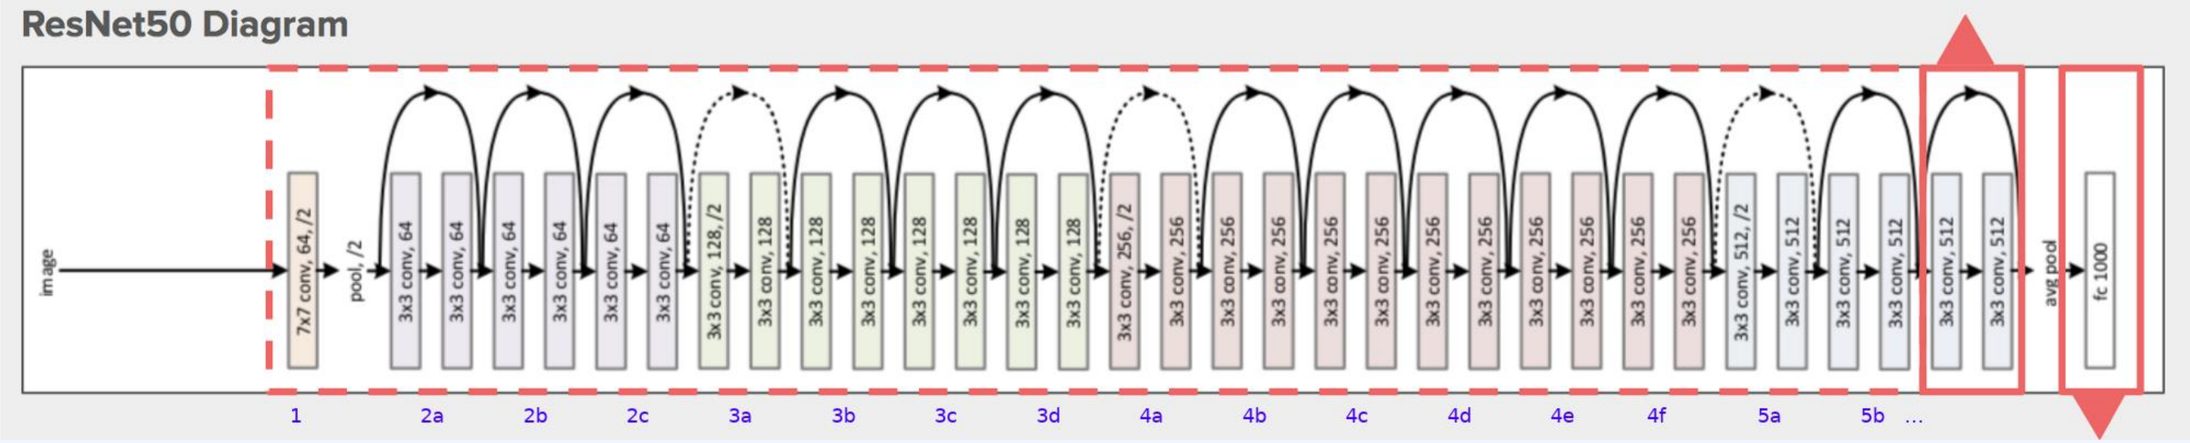

https://stackoverflow.com/questions/54207410/how-to-split-resnet50-model-from-top-as-well-as-from-bottom 편집

ResNet

- skip connection
  - layer의 입력을 layer의 출력에 바로 연결
  - H(x) = F(x) + x

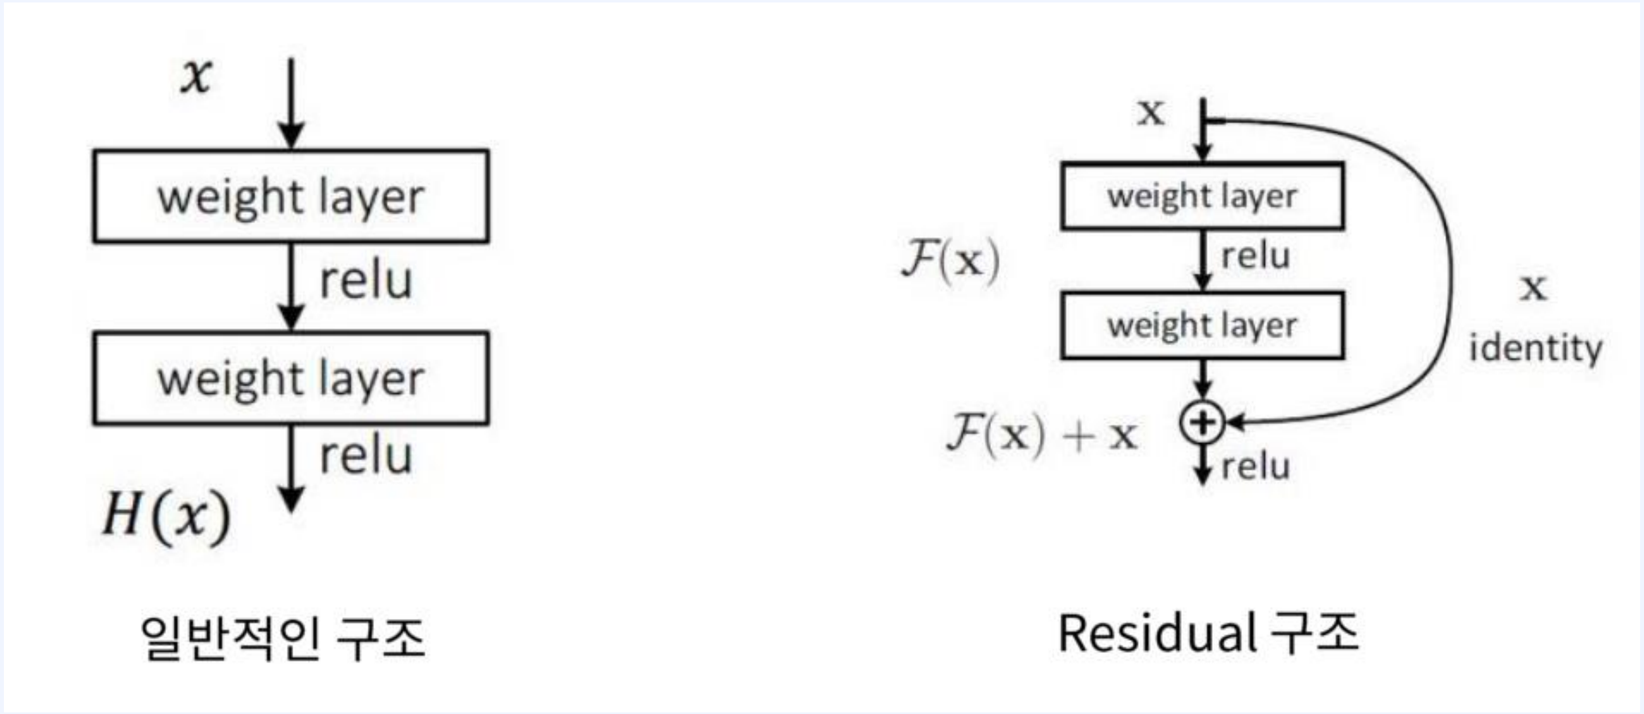

ResNet

➢ Residual 구조
- 일반적인 신경망: H(x)를 얻기 위해 학습을 수행
- ResNet: 잔차($F(x) = H(x) - x$)를 최소화하는 방향으로 수행

➢ Residual 구조의 효과
- 깊은 층을 가지고 있지만 Gradient vanishing이 발생하지 않고 학습이 잘 됨

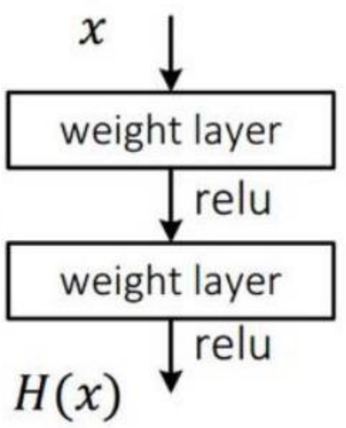

일반적인 구조

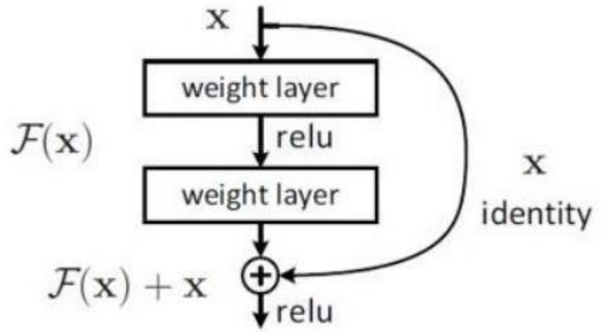

Residual 구조

$$H(x) = F(x) + x$$
$$F(x) = H(x) - x$$

Transfer Learning

- 기존의 만들어진 모델을 사용하여 새로운 모델을 만드는 방법
- 학습을 빠르게 하며 예측 성능을 더 높임
- 이미 잘 훈련된 모델이 있고, 특히 해당 모델과 유사한 문제를 해결 시 효과적

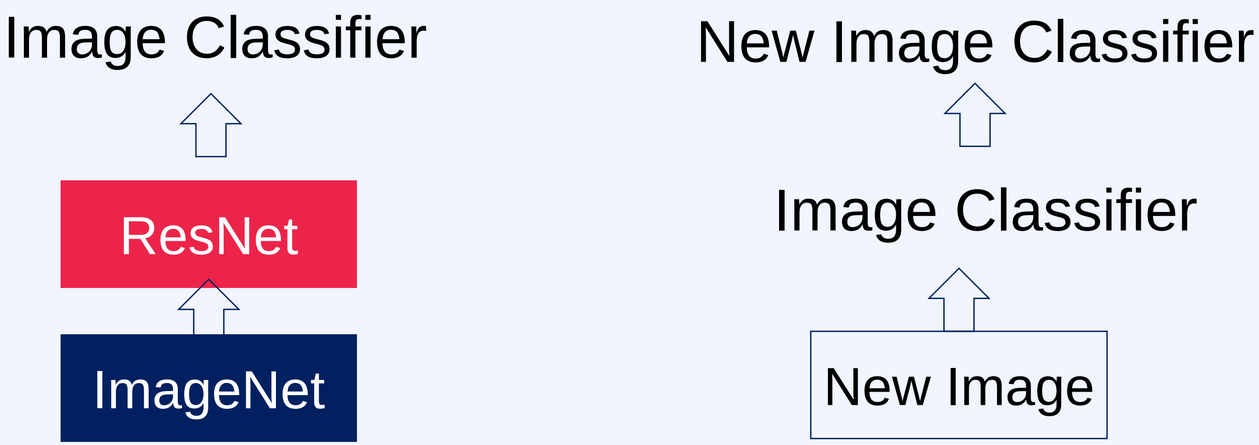

Transfer Learning

```
model_conv = torchvision.models.resnet18(pretrained=True)
for param in model_conv.parameters():
    param.requires_grad = False

# Parameters of newly constructed modules have requires_grad=True by default
num_ftrs = model_conv.fc.in_features
model_conv.fc = nn.Linear(num_ftrs, 2)

model_conv = model_conv.to(device)

criterion = nn.CrossEntropyLoss()

# Observe that only parameters of final layer are being optimized as
# opposed to before.
optimizer_conv = optim.SGD(model_conv.fc.parameters(), lr=0.001, momentum=0.9)

# Decay LR by a factor of 0.1 every 7 epochs
exp_lr_scheduler = lr_scheduler.StepLR(optimizer_conv, step_size=7, gamma=0.1)
```

https://pytorch.org/tutorials/beginner/transfer_learning_tutorial.html

!Transfer Learning

- VGGNet
  - 3x3 kernel
- Inception
  - Module
  - 1x1 kernel
  - Parallel filters
- ResNet
  - Skip-connection

EfficientNet

- depth, width, resolution을 동시에 고려한 compound scaling을 통해 ConvNet기반 이미지 분류 성능을 개선한 모델
- 목적: 이미지 분류
- 개선방향 : depth, width, resolution 동시에 키워서 성능 개선
  - width(필터의 개수 늘림), depth(레이어 수 늘림), resolution(이미지 해상도 키움)
- 성과: 연산은 줄이고, 정확도는 높임

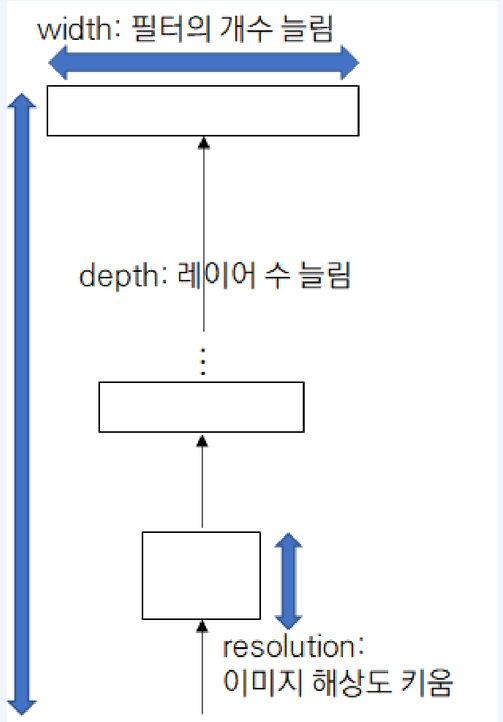

Quiz

```
import torch.nn as nn
from torchvision import models
net = models.resnet18(pretrained=True)
for p in net.parameters():
    p.requires_grad = False
fc_input_dim = net.fc.in_features
net.fc = nn.Linear(fc_input_dim, 2)
```

Q 다음 코드에 대한 설명으로 옳지 않은 것은?

① resnet18 신경망을 사용하여 전이학습을 수행하는 코드이다.

② 위의 코드를 사용하여 신경망을 학습하면 resnet18의 가중치는 변경된다.

③ 2개의 카테고리를 분류할 수 있는 태스크에 적합한 신경망이다.

④ resnet18 신경망은 이미 학습이 완료된 파라미터가 설정되어 호출된다.

해설

▶ resnet18의 requires_grad = False로 설정하였기 때문에 학습이 진행되더라도 가중치는 변경되지 않는다.

Quiz

Q 사전 학습된 모델을 새로운 문제에 적용하기 위해 일부 가중치를 조절하는 학습 과정을 무엇이라고 하는가?

① Fine tuning

② Few shot learning

③ Fast learning

④ Back propagation

해설

▶ 미세조정(Fine tuning)은 사전학습(pre-training) 모델을 사용하여 새로운 문제에 적용할 수 있도록 조정하는 과정이다.

Quiz

Q **VGG16 등 사전 훈련된 모델을 사용하는 주된 목적은?**

① 사용자가 만든 모델보다 CPU와 메모리 사용량이 적기 때문에

② 모든 변수가 자동으로 설정되어 사용자가 관여할 것이 없기 때문에

③ 사전 훈련된 모델을 사용할 경우, 사용자가 모델을 변경할 필요가 없기 때문에

④ 소규모 데이터셋에서 효과적으로 모델을 설계하고 훈련시킬 수 있기 때문에

해설

▶ 소규모 데이터셋에서 효과적으로 인공지능 모델을 설계하고 훈련시킬 수 있기 때문에 사전 훈련된 모델을 사용한다.

CNN

모델의 성능을 높이기 위해 사용하는 방법들

생각해보기

➢ 좋은 성능을 갖는 인공신경망이란?

- 일반화(Generalize) 측면
- 정확도(Accuracy) 측면
- 리소스(Memory and computation complexity) 측면
- 학습 속도 측면

인공신경망의 일반화를 위해서..

➢Overfitting을 막기 위한 방법

- 학습용 데이터를 늘린다.
- 이른 종료(Early stopping)
- Regularization : L2, L1, Dropout 등
- 앙상블 모델

학습용 데이터를 늘린다...

- Image Augmentation
  - 소규모 데이터 셋으로 강력한 학습 모델을 만드는 방법

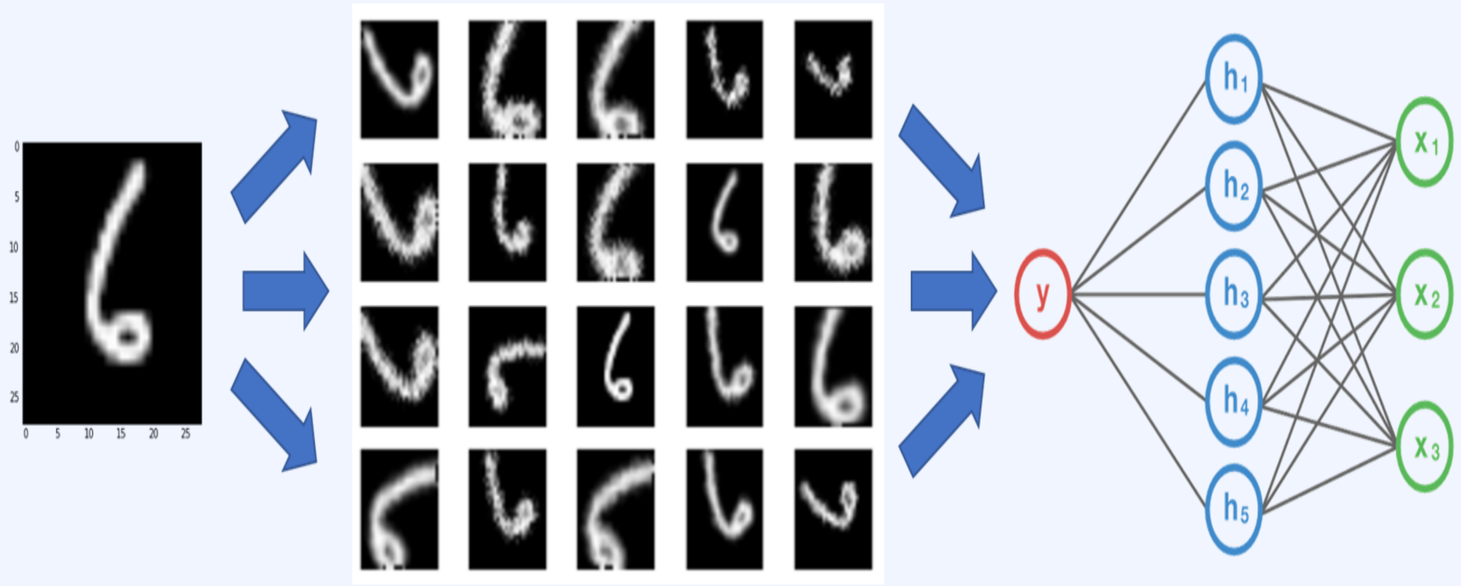

학습용 데이터를 늘린다...

- Image Augmentation
  - rotation, stretching, crop, flip …
  - 비슷해보이지만, 데이터는 다르다

Original

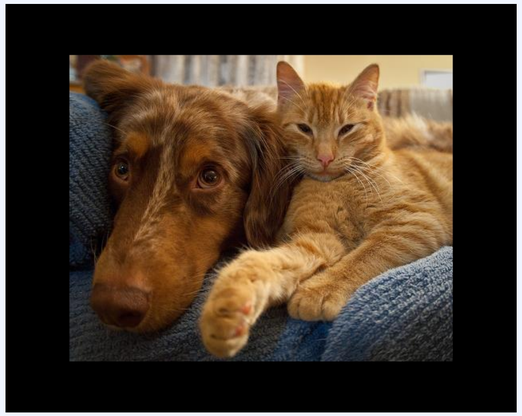

https://mlnotebook.github.io/post/dataaug/

이른 종료(Early stopping)

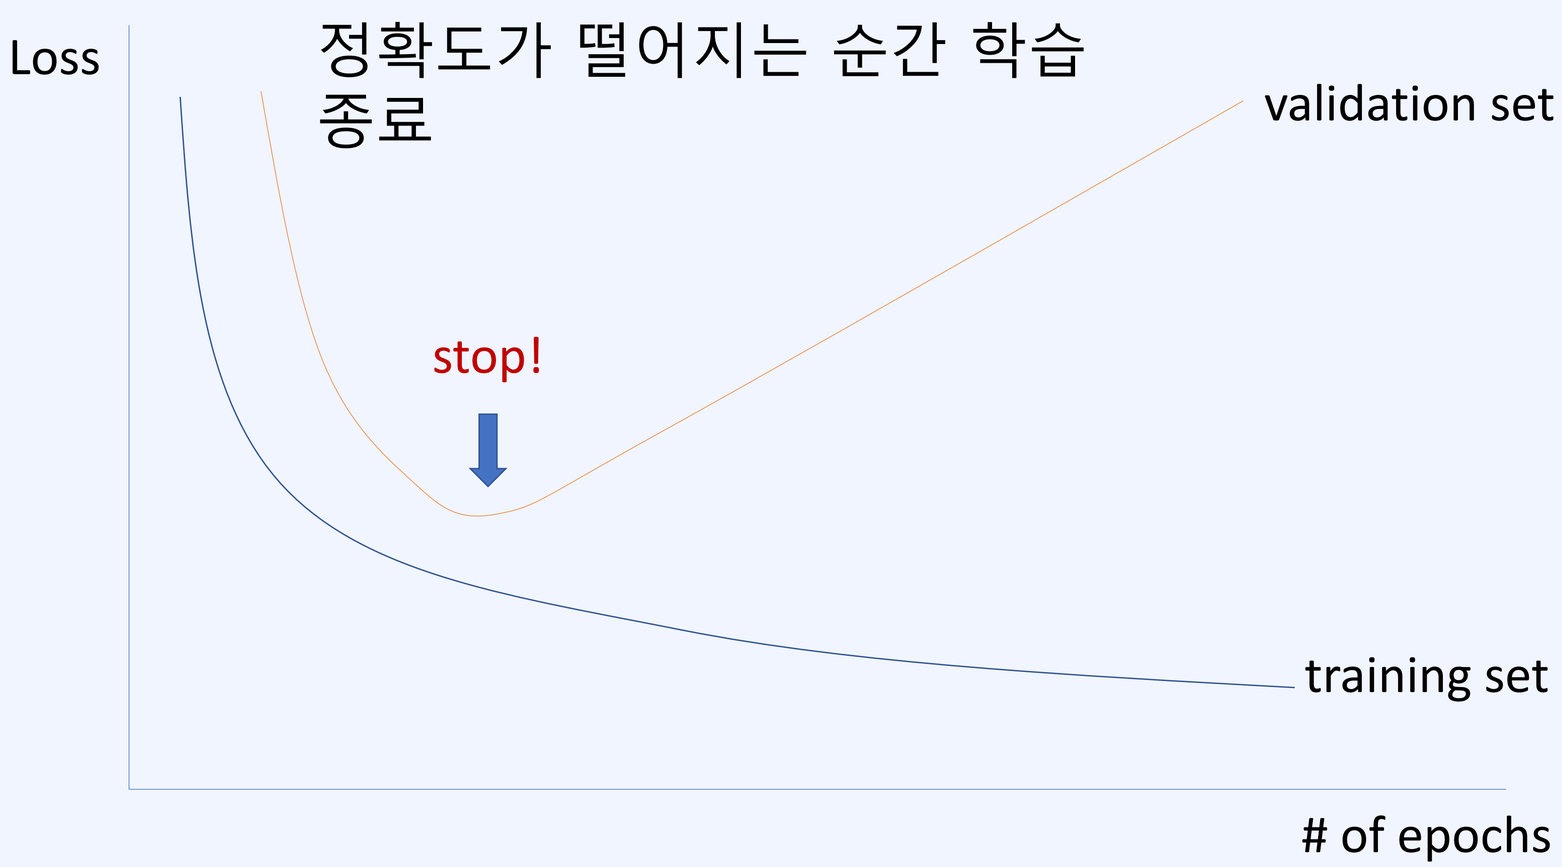

Dropout

- 학습 중에 은닉층의 뉴런을 무작위로 삭제하여 과적합을 예방하는 기법
- dropout(p)
  - p라는 확률로 출력 노드의 신호를 보내다 말다 함
  - 드롭아웃을 적용한 다음에 오는 계층은 앞 계층의 일부 노드들의 신호가 p라는 확률로 단절되기 때문에 훨씬 더 견고하게 신호에 적응

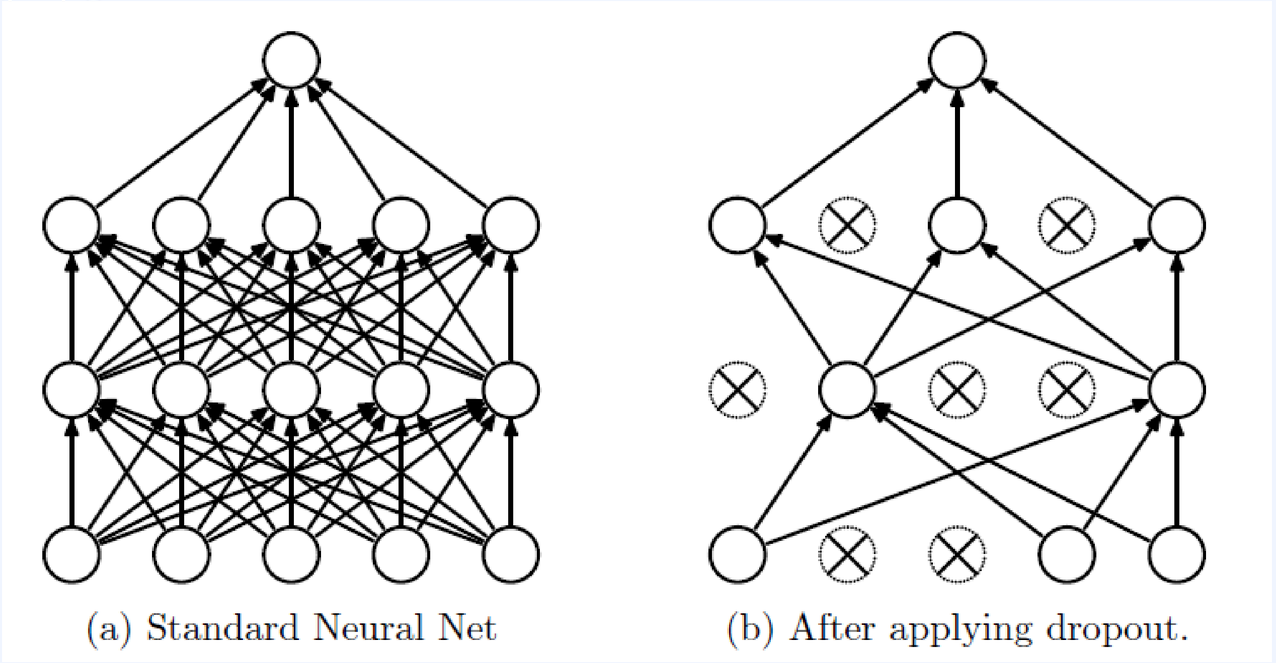

(a) Standard Neural Net (b) After applying dropout.

Feature map의 사이즈를 줄이기 위한 방법

➢Pooling

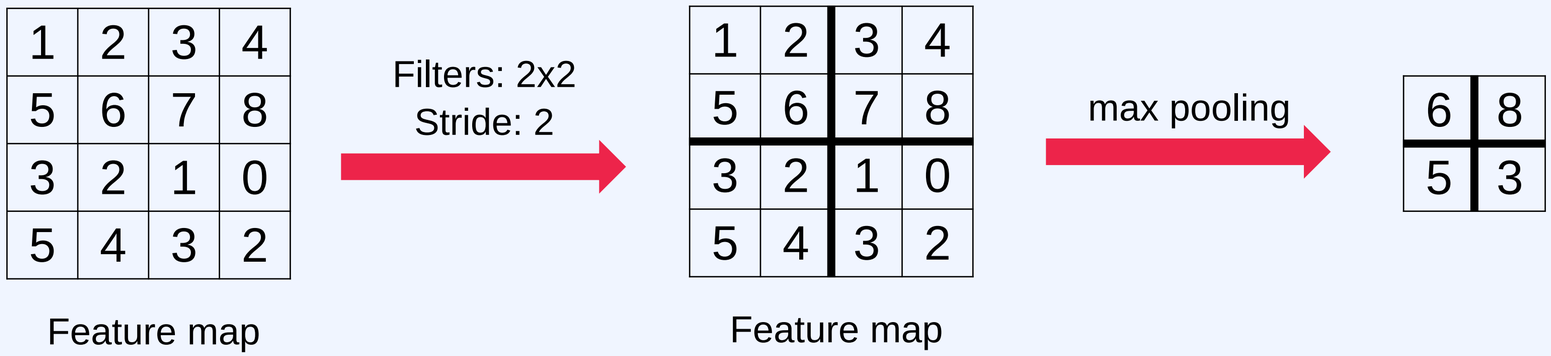

➢Stride

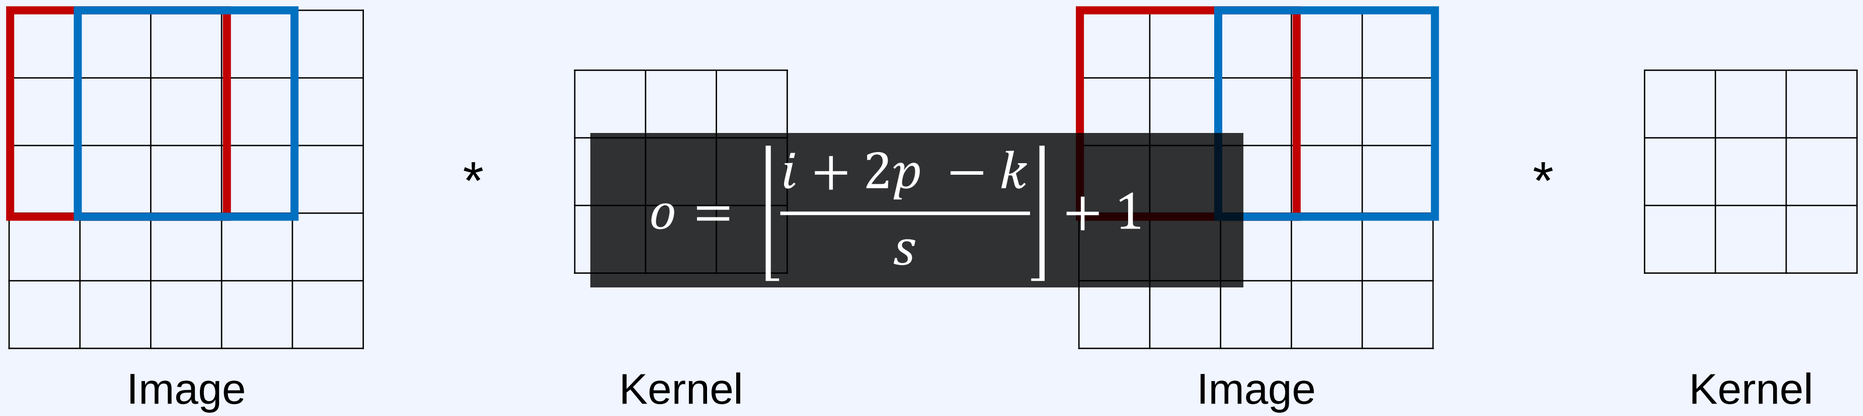

Batch Normalization

➢ 한 번에 입력으로 들어오는 배치 단위로 데이터 분포의 평균이 0, 분산이 1이 되도록 정규화 진행
- 빠른 학습 가능: learning rate를 높게 잡을 수 있음
- 자체적인 regularization 효과

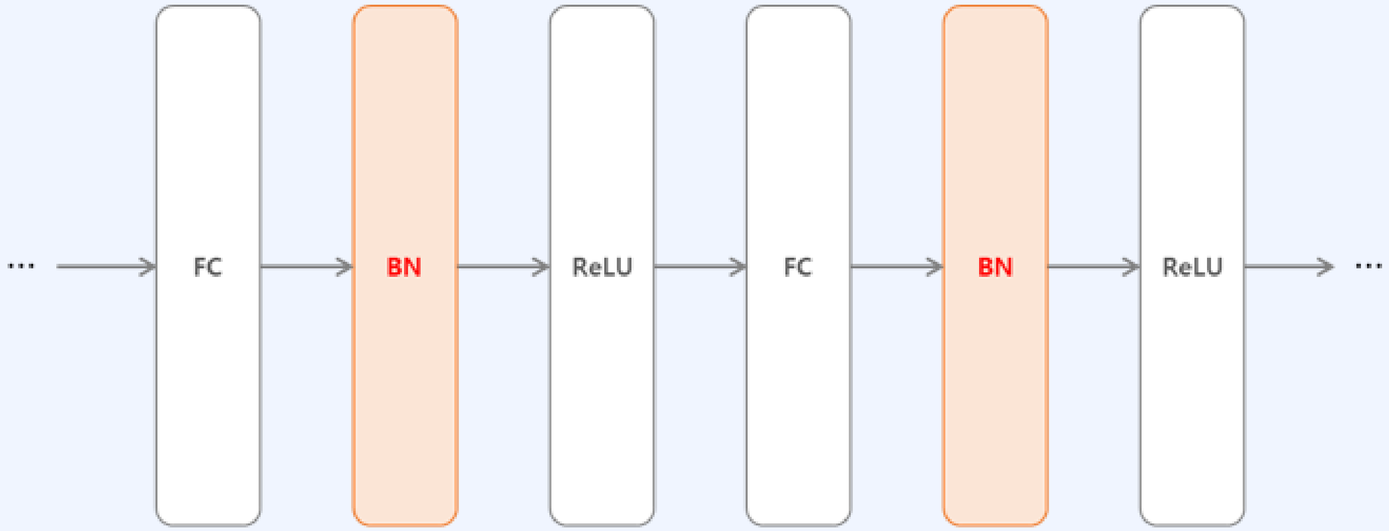

[BN을 사용한 신경망 예]

Weight Initialization

➢ Xavier Initialization

- **paper**: Xavier Glorot and Yoshua Bengio. "**Understanding the difficulty of training deep feedforward neural networks**." Proceedings of the thirteenth international conference on artificial intelligence and statistics. 2010.
- **activation function** : tanh, sigmoid

torch.nn.init.xavier_uniform_(*tensor*, *gain=1.0*) [SOURCE]

Fills the input *Tensor* with values according to the method described in *Understanding the difficulty of training deep feedforward neural networks* - Glorot, X. & Bengio, Y. (2010), using a uniform distribution. The resulting tensor will have values sampled from $\mathcal{U}(-a, a)$ where

$$a = \text{gain} \times \sqrt{\frac{6}{\text{fan\_in} + \text{fan\_out}}}$$

Also known as Glorot initialization.

torch.nn.init.xavier_normal_(*tensor*, *gain=1.0*) [SOURCE]

Fills the input *Tensor* with values according to the method described in *Understanding the difficulty of training deep feedforward neural networks* - Glorot, X. & Bengio, Y. (2010), using a normal distribution. The resulting tensor will have values sampled from $\mathcal{N}(0, \text{std}^2)$ where

$$\text{std} = \text{gain} \times \sqrt{\frac{2}{\text{fan\_in} + \text{fan\_out}}}$$

Also known as Glorot initialization.

➢ He Initialization

- **paper**: Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. "**Delving deep into rectifiers: Surpassing human-level performance on imagenet classification**." In Proceedings of the IEEE international conference on computer vision, pp. 1026-1034. 2015.
- **activation function** : relu

Summary

➢ 좋은 성능을 갖는 인공신경망이란?

- 일반화(Generalize) 측면
- 정확도(Accuracy) 측
- 리소스(Memory and
- 학습 속도 측면

Image Augmentation, Early stopping, Regularization(L2, L1),

Dropout, 앙상블 모델, Batch Normalization, Weight Initialization,

Pooling, Stride,

3x3 kernel, 1x1 kernel, Skip connection,

Transfer learning

CNN

1D Conv

Remind

➢ Convolution 연산은 이미지에만 적용되는 것이 아니다!

합성곱

문서 토론

위키백과, 우리 모두의 백과사전.

합성곱(合成-), 또는 **콘벌루션**(convolution)은 하나의 함수와 또 다른 함수를 반전 이동한 값을 곱한 다음, 구간에 대해 적분하여 새로운 함수를 구하는 수학 연산자이다.

정의 [편집]

두 개의 함수 f와 g가 있을 때, 두 함수의 합성곱을 수학 기호로는 $f * g$와 같이 표시한다.

합성곱 연산은 두 함수 f, g 가운데 하나의 함수를 반전(reverse), 전이(shift)시킨 다음, 다른 하나의 함수와 곱한 결과를 적분하는 것을 의미한다. 이를 수학 기호로 표시하면 다음과 같다.

$$(f * g)(t) = \int_{-\infty}^{\infty} f(\tau) g(t - \tau)\, d\tau$$

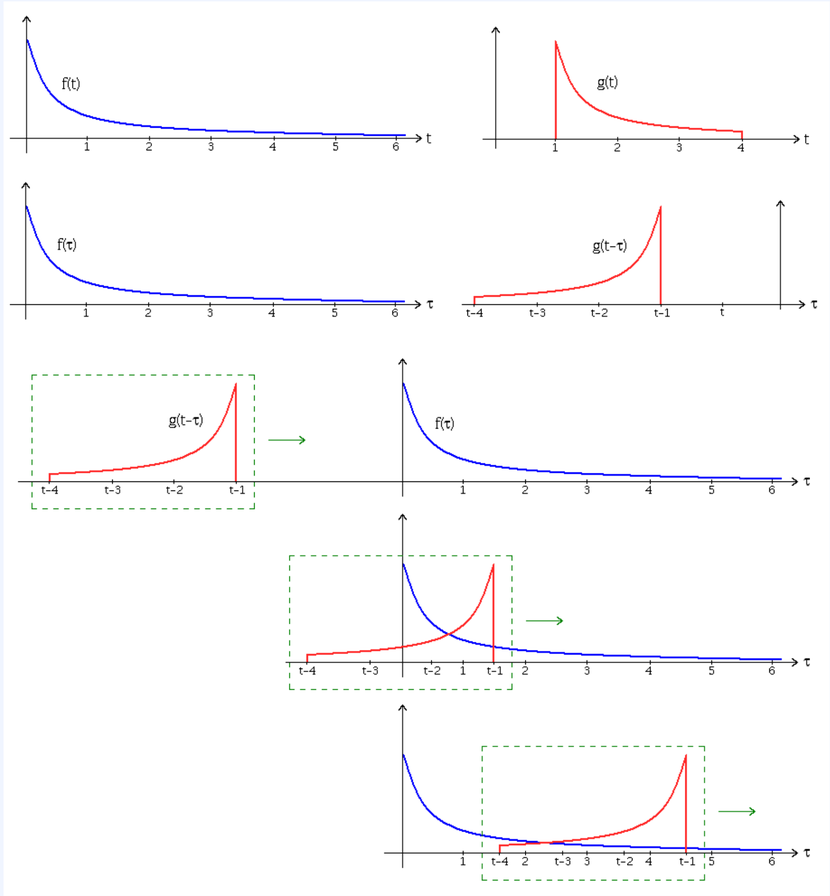

출처: 위키백과

Conv1D

➢ Text Classification with Conv1D

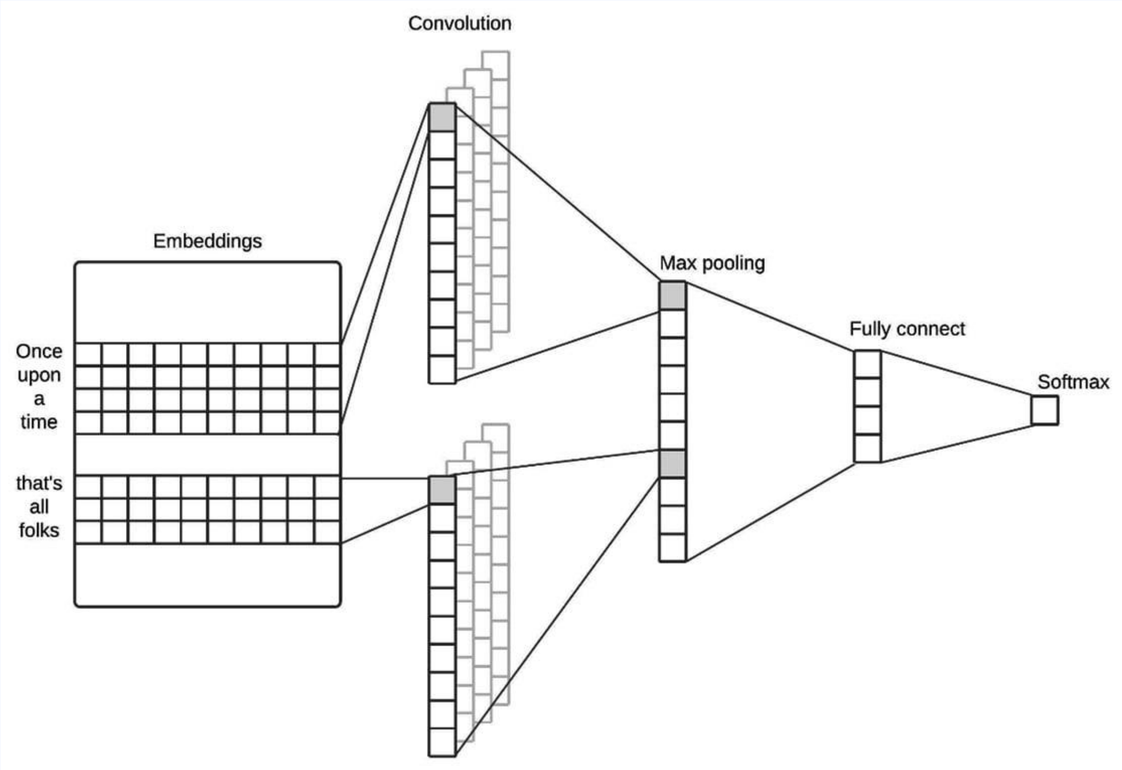

Layer (type)	Output Shape	Param #
embedding_1 (Embedding)	(None, 1500, 50)	4429150
conv1d_1 (Conv1D)	(None, 1500, 64)	12864
max_pooling1d_1 (MaxPooling1	(None, 750, 64)	0
conv1d_2 (Conv1D)	(None, 750, 128)	24704
dropout_1 (Dropout)	(None, 750, 128)	0
max_pooling1d_2 (MaxPooling1	(None, 375, 128)	0
conv1d_3 (Conv1D)	(None, 375, 256)	65792
dropout_2 (Dropout)	(None, 375, 256)	0
max_pooling1d_3 (MaxPooling1	(None, 187, 256)	0
dense_1 (Dense)	(None, 187, 128)	32896
dropout_3 (Dropout)	(None, 187, 128)	0
dense_2 (Dense)	(None, 187, 64)	8256
global_max_pooling1d_1 (Glob	(None, 64)	0
dense_3 (Dense)	(None, 1)	65

https://subscription.packtpub.com/book/data/9781800567641/7/ch07lvl1sec35/one-dimensional-cnns-conv1d
https://www.kaggle.com/code/sumitdua10/cnn-notebook-on-text-classification

Conv1D

➢ Time series data with Conv1D

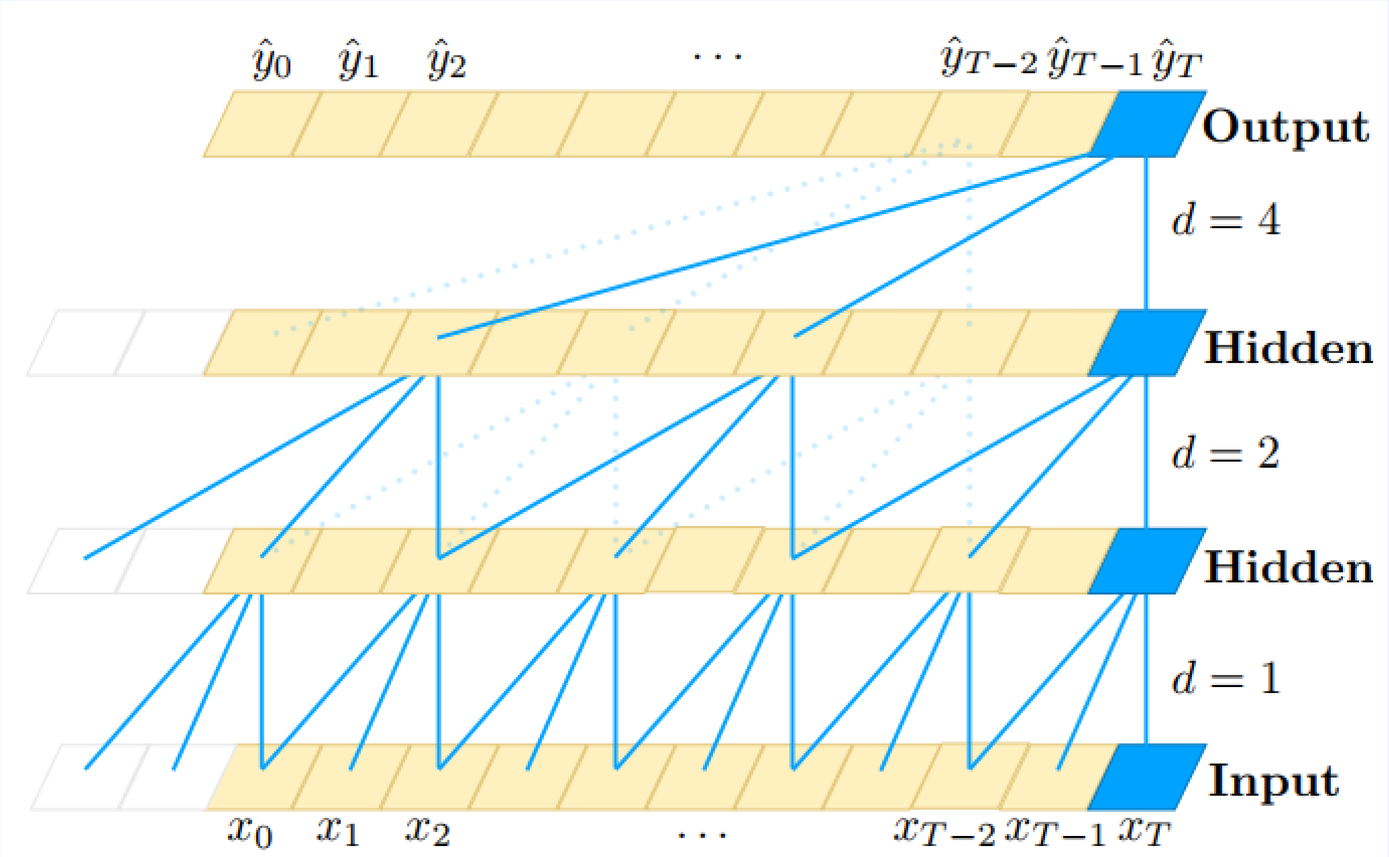

Shaojie Bai , J. Zico Kolter, Vladlen Koltun, An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling

Dilated Convolution

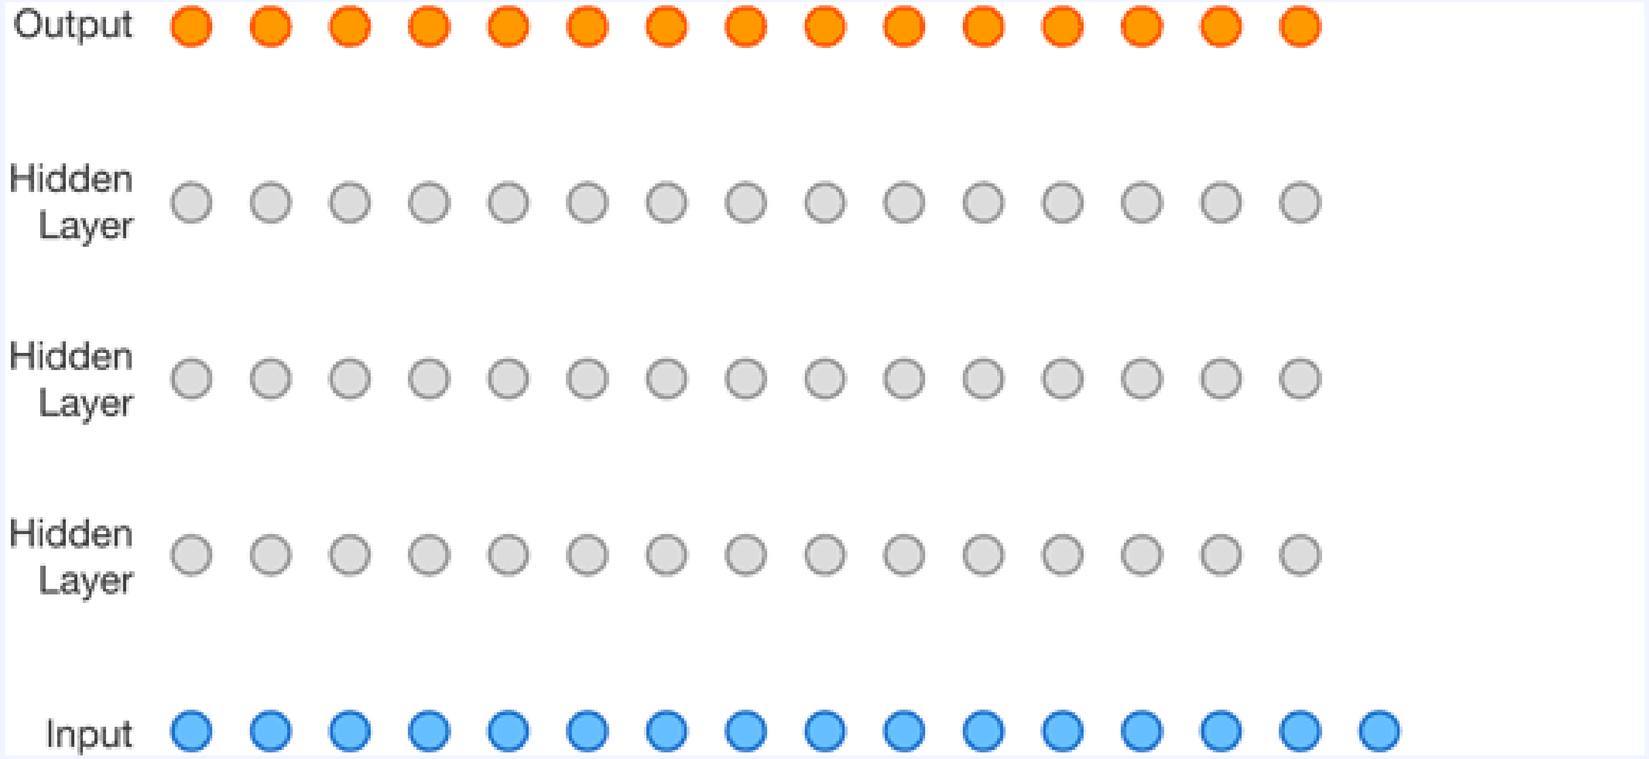

https://www.deepmind.com/blog/wavenet-a-generative-model-for-raw-audio

Transposed Convolutions

➢ Paper: A guide to convolution arithmetic for deep learning(Dumoulin, V., & Visin, F., 2016)

➢ Convolution
- Input: 5x5
- Kernel: 3x3
- Stride: 2
- Padding: 0
- Ouput: 2x2

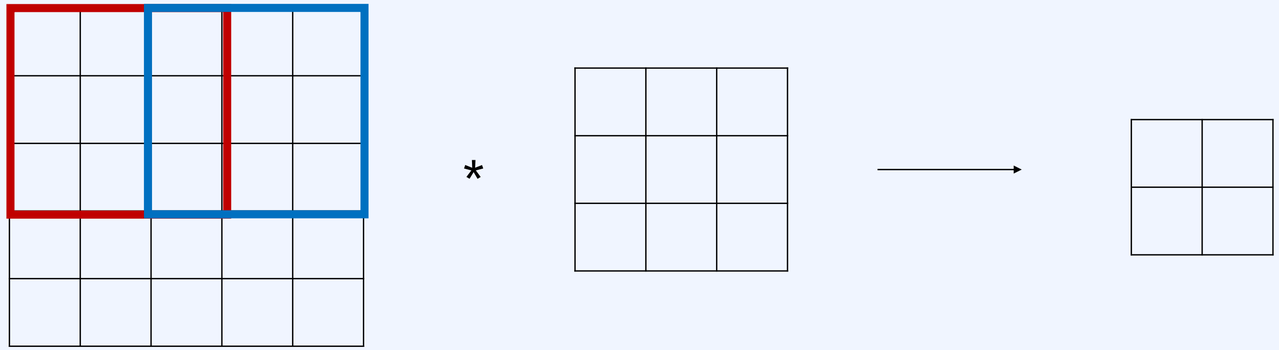

Input Kernel Output

Transposed Convolutions

- Transposed Convolutions
  - Input: 2x2 (1 zero inserted between inputs)
  - Kernel: 3x3
  - Stride: 1
  - Padding: 2x2
  - Ouput: 5x5

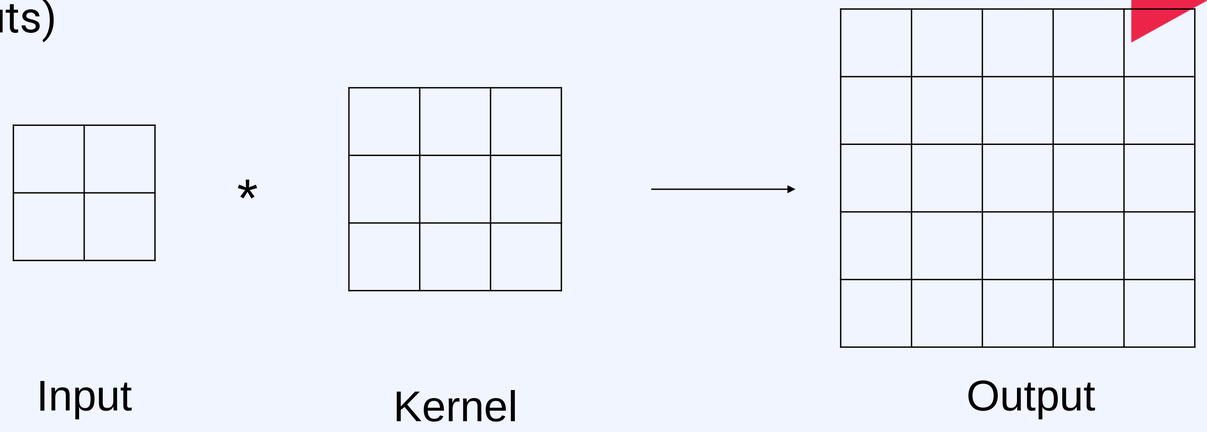

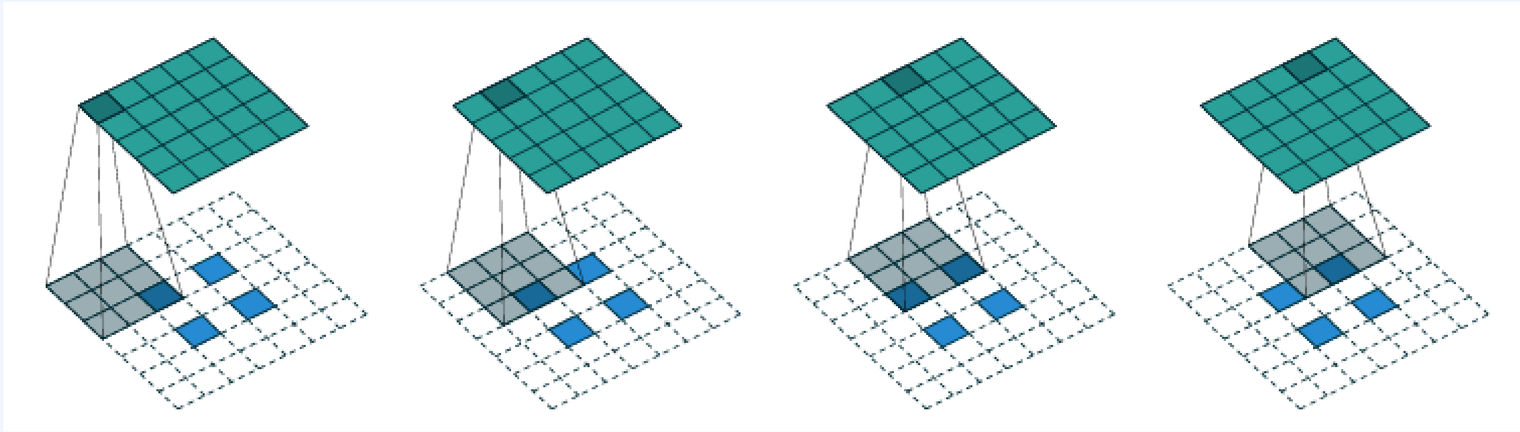

[이미지 출처] https://arxiv.org/pdf/1603.07285.pdf

Closing

CNN